

MARO 036 - Optimisation Non-Linéaire

Arnaud Vandaele

Faculté Polytechnique
Service MATHématique et Recherche Opérationnelle



Année académique 2024-2025

Séance 1 :
Rappels et introduction

Séance 1 – Rappels et introduction

Tables des matières

- 1 Introduction au cours
- 2 Définitions et rappels
- 3 Globalement, il n'y a pas d'espoir
- 4 Introduction aux conditions d'optimalité

Plan

- 1 Introduction au cours
- 2 Définitions et rappels
- 3 Globalement, il n'y a pas d'espoir
- 4 Introduction aux conditions d'optimalité

Organisation du cours et fiche ECTS

- Support : transparents.
- La présence aux séances pratiques et séminaires éventuels est obligatoire. Une présence aux cours de théorie/exercices de minimum 80% est requise.

- Evaluation:

Dans le cas où l'étudiant a respecté les contraintes de présence, la note finale (/20) de l'AA se base sur trois notes :

- une note A (/20) permettant d'évaluer la compréhension de l'enseignement lors d'un examen écrit
- une note B (/20) permettant d'évaluer la capacité d'implémentation de méthodes pour résoudre des problèmes d'optimisation lors d'un examen oral et/ou de travaux pratiques

Si les notes A et B sont ≥ 7 , alors $\text{notefinale} = (A + B)/2$. Si une des notes est < 7 , alors la note finale sera égale à la note minimale, c-à-d : $\text{notefinale} = \text{minimum}(A, B)$.

Dans le cas où l'étudiant n'a pas respecté les contraintes de présence la note de l'AA sera évaluée lors d'un examen oral.

- Questions ?

Motivation : modélisation et aide à la décision

Aider à choisir la **meilleure** décision

$$\left. \begin{array}{ll} \text{Décision} & \leftrightarrow \text{vecteur de variables } x \\ \text{Meilleure} & \leftrightarrow \text{fonction objectif } f \\ \text{Contraintes} & \leftrightarrow \text{domaine admissible } X \end{array} \right\} \Rightarrow \text{Optimisation}$$

$$\min_x f(x) \quad \text{tel que} \quad x \in X.$$

- **Nombreuses** applications en pratique
- Méthodes de résolution **efficaces** en pratique
- Modélisation et résolution de modèles de **grande** taille


Optimisation non-linéaire : optimisation numérique

Si on souhaite trouver le minimum de la fonction :

$$f(x) = e^x + \cos x,$$

à un moment donné, il faut pouvoir résoudre l'équation :

$$f'(x) = 0, \text{ c'est-à-dire } e^x - \sin(x) = 0.$$



Analytiquement, ce n'est pas possible.

L'optimisation non-linéaire est donc majoritairement consacrée à l'étude de **méthodes numériques** permettant d'optimiser des fonctions.

Notations et écriture générale

La minimisation d'une fonction $f : \mathbb{R}^n \rightarrow \mathbb{R}$ sur un domaine X s'écrit

$$\begin{aligned} &\min_x f(x) \\ &\text{t.q. } x \in X. \end{aligned}$$

Le domaine X est souvent défini à l'aide de **contraintes** fonctionnelles :

$$X = \{x \in \mathbb{R}^n \mid h_i(x) = 0 \text{ pour } i \in \mathcal{E} \text{ et } h_i(x) \geq 0 \text{ pour } i \in \mathcal{I}\}.$$

Les contraintes h_i sont des fonctions $h_i : \mathbb{R}^n \rightarrow \mathbb{R}$:

- $h_i(x) = 0$ est une **contrainte d'égalité** pour tout indice $i \in \mathcal{E}$
- $h_i(x) \geq 0$ est une **contrainte d'inégalité** pour tout indice $i \in \mathcal{I}$

($\mathcal{E}$ et $\mathcal{I}$ sont des ensembles d'**indices** repérant les contraintes)

Le problème général peut donc également s'écrire :

$$\begin{aligned} &\min_x f(x) \\ &\text{t.q. } \begin{aligned} &h_i(x) = 0 \text{ pour } i \in \mathcal{E} \\ &h_i(x) \geq 0 \text{ pour } i \in \mathcal{I} \end{aligned} \end{aligned}$$

Cas particulier : si toutes les fonctions sont linéaires

$$\min_x f(x)$$


$$\text{t.q. } h_i(x) = 0 \text{ pour } i \in \mathcal{E}$$

$$h_i(x) \geq 0 \text{ pour } i \in \mathcal{I}$$

Si toutes les fonctions f et h_i sont linéaires, le problème peut se simplifier en :

$$\begin{array}{ll} \min & c^T x \\ \text{tel que} & Ax \geq b. \end{array}$$

- Les contraintes $Ax \geq b$ forment un espace de solutions admissibles qui est un **polyèdre** (un polytope si borné et non vide).
- L'objectif $c^T x$ forme un **hyperplan** translatant dans l'espace.



(dans la plupart des cas, une solution optimale sera un des sommets du polyèdre)

Linéaire vs. non-linéaire

Pourquoi étudier l'optimisation linéaire ?

- Parce que de nombreux problèmes sont modélisables linéairement
- Parce qu'il existe un algorithme très efficace (l'algorithme du simplexe) pour résoudre ces problèmes
- Parce que ces problèmes disposent d'une structure très riche (propriétés d'optimalité, de dualité)

Pourquoi étudier l'optimisation non-linéaire ?

- Parce que certains problèmes sont impossibles à modéliser linéairement
- Parce que l'algorithme du simplexe pour l'optimisation linéaire est inapplicable aux problèmes non-linéaires
- Parce qu'il existe des liens étroits entre la formulation (choix du modèle) et la résolution (choix de la méthode) d'un problème d'optimisation non-linéaire

Sommaire du cours

Partie I – Optimisation linéaire

Partie II – Optimisation non-linéaire

0. Optimisation non-linéaire

- Problèmes traités, définitions et terminologie

1. Modèles


- Conditions d'optimalité
 - Problèmes sans contraintes
 - Problèmes avec contraintes
- Problèmes convexes
 - Reconnaître un problème convexe
 - Propriétés des problèmes convexes

2. Méthodes


- Méthodes de recherche en ligne
 - Problèmes sans contraintes : méthodes au premier et second ordre
 - Convergence globale et locale
 - Détails d'implémentation
- Autres méthodes (y compris introduction au cas avec contraintes)

Références

- Nocedal, Wright, *Numerical Optimization*, Springer-Verlag, 1999



- Michel Bierlaire, *Introduction à l'optimisation différentiable*, PPUR, 2006



- Nicolas Gillis, *Notes de cours*, FPMs

Plan

1 Introduction au cours

2 Définitions et rappels

- Gradient et matrice hessienne
- Caractéristiques d'une matrice
- Notation matricielle pour une fonction quadratique
- Développement de Taylor
- Continuité au sens de Lipschitz

3 Globalement, il n'y a pas d'espoir

4 Introduction aux conditions d'optimalité

Gradient et matrice hessienne $\mathbb{R}^n \rightarrow \mathbb{R}$

Pour une fonction f différentiable,
la fonction notée $\nabla f(x)$ est appelée le gradient de f et est définie par :

$$\nabla f(x) = \begin{pmatrix} \frac{\partial f(x)}{\partial x_1} \\ \vdots \\ \frac{\partial f(x)}{\partial x_n} \end{pmatrix}.$$

Pour une fonction f deux fois différentiable,
la fonction notée $\nabla^2 f(x)$ est appelée matrice hessienne et est définie par :

$$\nabla^2 f(x) = \begin{pmatrix} \frac{\partial^2 f(x)}{\partial x_1^2} & \cdots & \frac{\partial^2 f(x)}{\partial x_1 \partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f(x)}{\partial x_n \partial x_1} & \cdots & \frac{\partial^2 f(x)}{\partial x_n^2} \end{pmatrix}.$$

Exemple. Calculez le gradient et la matrice hessienne de :

- $f_1(x_1, x_2) = \frac{1}{2}x_1^2 + 2x_2^2$
- $f_2(x_1, x_2, x_3) = e^{x_1} + x_1^2 x_3 - x_1 x_2 x_3$

Matrice (semi)définie positive, négative, indéfinie

Soit une matrice $A \in \mathbb{R}^{n \times n}$ symétrique et son spectre $\{\lambda_1, \dots, \lambda_n\}$.

- A définie positive :

$$\begin{aligned} A \succ 0 &\Leftrightarrow \lambda_i > 0 \quad \forall i \\ &\Leftrightarrow x^T A x > 0 \quad \forall x \in \mathbb{R}^n \text{ et } x \neq 0 \end{aligned}$$

- A semi-définie positive :

$$\begin{aligned} A \succeq 0 &\Leftrightarrow \lambda_i \geq 0 \quad \forall i \\ &\Leftrightarrow x^T A x \geq 0 \quad \forall x \in \mathbb{R}^n \text{ et } x \neq 0 \end{aligned}$$

Soit une matrice $A \in \mathbb{R}^{n \times n}$ symétrique.

- A définie négative $\Leftrightarrow -A$ est définie positive.
- A semi-définie négative $\Leftrightarrow$ une valeur propre = 0 et les autres négatives.

Une matrice $A \in \mathbb{R}^{n \times n}$ symétrique est **indéfinie** si et seulement si elle a au moins une valeur propre strictement positive et une valeur propre strictement négative.

Matrice (semi)définie positive, négative, indéfinie

Exemples

$$A = \begin{pmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{pmatrix}.$$

■ $\lambda_1 = 2, \lambda_2 = 2 - \sqrt{2}, \lambda_3 = 2 + \sqrt{2}.$

■ $x^T A x = x_1^2 + (x_1 - x_2)^2 + (x_2 - x_3)^2 + x_3^2$

$$A = \begin{pmatrix} 2 & -1 & -1 \\ -1 & 2 & -1 \\ -1 & -1 & 2 \end{pmatrix}.$$

■ $\lambda_1 = 0, \lambda_2 = 3, \lambda_3 = 3.$

■ $x^T A x = (x_1 - x_2)^2 + (x_2 - x_3)^2 + (x_3 - x_1)^2$

Notation matricielle pour une fonction quadratique

Une fonction $f : \mathbb{R}^n \rightarrow \mathbb{R}$ est dite quadratique si elle peut s'écrire sous la forme

$$f(x) = \frac{1}{2}x^T A x - b^T x + c,$$

où $A \in \mathbb{R}^{n \times n}$ et symétrique, $b \in \mathbb{R}^n$ et $c \in \mathbb{R}$. Nous avons alors :

$$\text{vecteur gradient : } \nabla f(x) = Ax - b,$$

$$\text{mat. hessienne : } \nabla^2 f(x) = A.$$

La matrice A peut **toujours** être symétrique. Si ce n'est pas le cas, on a :

$$x^T A x = \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j = \sum_{i=1}^n \sum_{j=1}^n \frac{1}{2} (a_{ij} + a_{ji}) x_i x_j.$$

On construit A' **symétrique** telle que $a'_{ij} = a'_{ji} = \frac{1}{2}(a_{ij} + a_{ji})$ et $x^T A x = x^T A' x$.

Exercice. Comment écrire $f(x_1, x_2) = 3x_1^2 + 4x_1x_2 + 6x_2^2 - 3x_1 + 5x_2 - 7$?

$$* \nabla f_1(x) = \begin{pmatrix} x_1 \\ 4x_2 \end{pmatrix} \rightarrow \nabla^2 f_1(x) = \begin{pmatrix} 1 & 0 \\ 0 & 4 \end{pmatrix}$$

$$* \nabla f_2(x) = \begin{pmatrix} x_1 \\ e^{x_1 + 2x_3} - x_3 & 2x_1 x_3 \\ -x_1 x_3 \\ x_1^2 - x_1 x_2 \end{pmatrix} \rightarrow \nabla^2 f_2(x) = \begin{pmatrix} e^{x_1 + 2x_3} - x_3 & 2x_1 x_3 \\ -x_3 & 0 & -x_1 \\ 2x_1 - x_2 & -x_1 & 0 \end{pmatrix}$$



Produits

$$* 2 \text{ vecteurs : } x = \begin{pmatrix} x_1 \\ \vdots \\ x_m \end{pmatrix}, y = \begin{pmatrix} y_1 \\ \vdots \\ y_m \end{pmatrix}$$

$$\hookrightarrow x^T y = (x_1 \dots x_m) \begin{pmatrix} y_1 \\ \vdots \\ y_m \end{pmatrix} = x_1 y_1 + \dots + x_m y_m \text{ scalaire!}$$

Valeurs et vecteurs propres

$Ax = \lambda x \rightarrow x$ vect. propre et λ valeur propre

* $m=1$: $\rightarrow$ Si $a > 0$  $ax^2 \geq 0 \forall x$
forme quadratique
"ax²" $\rightarrow$ Si $a < 0$  $ax^2 \leq 0 \forall x$

* $m \geq 2$: $m=2$: $x^T A x = (x_1 \ x_2) \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$
forme quadratique
"x^TAx" $= a_{11}x_1^2 + (a_{12} + a_{21})x_1x_2 + a_{22}x_2^2$

Théorème spectral

Pour A de taille $n \times n$ symétrique,

A possède n valeurs propres réelles $\lambda_1, \dots, \lambda_n$

A possède n vecteurs propres orthogonaux $v_1, \dots, v_n$
forme une base de $\mathbb{R}^n$


Par le th. spectral, $\forall x \in \mathbb{R}^m$, on a : $x = \alpha_1 v_1 + \dots + \alpha_m v_m$

$$\hookrightarrow \text{Si } x = v_i : x^T A x = v_i^T A v_i = v_i^T (\lambda_i v_i) = \lambda_i v_i^T v_i = \lambda_i$$

$$\hookrightarrow \text{Si } x = \alpha_1 v_1 + \dots + \alpha_m v_m :$$

$$\begin{aligned} x^T A x &= (\alpha_1 v_1 + \dots + \alpha_m v_m)^T A (\alpha_1 v_1 + \dots + \alpha_m v_m) \\ &= \alpha_1^2 v_1^T A v_1 + \cancel{\alpha_1 \alpha_2 (v_1^T A v_2)} + \dots + \cancel{\alpha_1 \alpha_m (v_1^T A v_m)} \\ &\quad + \cancel{\alpha_2 \alpha_1 (v_2^T A v_1)} + \alpha_2^2 v_2^T A v_2 + \dots + \cancel{\alpha_2 \alpha_m (v_2^T A v_m)} \\ &\quad + \dots \\ &= \alpha_1^2 \lambda_1 + \dots + \alpha_m^2 \lambda_m \end{aligned}$$

$\hookrightarrow$ D'où l'équilibre : $A \succ 0 \Leftrightarrow \lambda_i > 0 \quad \forall i \Leftrightarrow x^T A x > 0 \quad \forall x$



$$\|x\|^2 \lambda_{\min} \leq x^T A x \leq \lambda_{\max} \|x\|^2$$

Imaginons une matrice où toutes les valeurs propres > 0
sauf une qui est $\lambda_{\min} < 0$

$$\text{Avec } x = v_{\min}, \text{ on a } v_{\min}^T A v_{\min} = \lambda_{\min} < 0$$

r
(
(
,

Développement de Taylor à l'ordre 1 et 2

L'**approximation** par développement de **Taylor** est un outil essentiel pour caractériser l'optimalité. Il est donc nécessaire que les fonctions (objectif et contraintes) du problème d'optimisation soient suffisamment **différentiables**.

Pour une fonction à plusieurs variables $f : \mathbb{R}^n \rightarrow \mathbb{R}$, on a :

$$f(x) = P(x) + R(x)$$

Lors d'un développement d'ordre k , le comportement du reste $R(x)$ s'apparente à $(x - a)^{k+1}$. Lorsque x s'approche de a , le terme $R(x)$ devient négligeable par rapport à $(x - a)^k$, on note cela $R(x) = o(\|x - a\|^k)$.

- Pour Taylor à l'ordre $k = 1$, f doit être continûment différentiable :

$$\begin{aligned} f(x) &= f(a) + (x - a)^T \nabla f(a) + o(\|x - a\|), \\ f(a + \alpha d) &= f(a) + \alpha d^T \nabla f(a) + o(\|\alpha d\|) = f(a) + \alpha d^T \nabla f(a) + o(|\alpha|). \end{aligned}$$

- Pour Taylor à l'ordre $k = 2$, f doit être deux fois continûment différentiable :

$$\begin{aligned} f(x) &= f(a) + (x - a)^T \nabla f(a) + \frac{1}{2} (x - a)^T \nabla^2 f(a) (x - a) + o(\|x - a\|^2), \\ f(a + \alpha d) &= f(a) + \alpha d^T \nabla f(a) + \frac{\alpha^2}{2} d^T \nabla^2 f(a) d + o(\|\alpha d\|^2) = f(a) + \alpha d^T \nabla f(a) + \frac{\alpha^2}{2} d^T \nabla^2 f(a) d + o(|\alpha|^2) \end{aligned}$$

Exemple.

Déterminer le modèle quadratique de $f(x_1, x_2) = ((x_1 + x_2)^2 - 1)^2$ au point $(\frac{1}{4}, \frac{1}{4})$. Ecrire ensuite le développement dans la direction $d = (1, 1)$.

Notation de Landau $o(\cdot)$ - Fonction négligeable

Soient $f, g : E \subseteq \mathbb{R} \rightarrow \mathbb{R}$. La notation $f(x) = o(g(x))$ indique que f est négligeable devant g au voisinage de a , ce qui est défini de la façon suivante :

$$\forall \varepsilon > 0, \exists \delta > 0 : \forall x \in E, x \in V_\delta^*(a) \implies |f(x)| \leq \varepsilon \cdot |g(x)|.$$

Cette expression permet de revenir à la définition d'une limite, on a donc :

$$f(x) = o(g(x)) \text{ au voisinage de } a \iff \lim_{x \rightarrow a} \frac{f(x)}{g(x)} = 0.$$

En d'autres mots, f est infiniment petit par rapport à g au voisinage de a , ou encore, f tend plus vite vers a que g .

Dans le cas d'un développement de Taylor à l'ordre k , cela signifie que :

$$\lim_{x \rightarrow a} \frac{R(x)}{(x - a)^k} = 0.$$

Notation de Landau $o(\cdot)$ - Fonction négligeable - Exemples

Exemples au voisinage de $a = 0$.

- Si on a $f(x) = o(x)$, cela signifie que $\forall \varepsilon > 0$, il existe un voisinage étoilé de rayon $\delta > 0$ tel que pour tout point x de ce voisinage, on a $|f(x)| < \varepsilon|x|$.

En ne considérant que la partie $]0, 0 + \delta]$ du voisinage étoilé, on peut donc en conclure qu'il existe $x_{\max} > 0$ tel que $\forall x \in]0, x_{\max}]$, on a :

$$\frac{|f(x)|}{x} < \varepsilon \quad \text{ou encore} \quad \frac{|o(x)|}{x} < \varepsilon.$$

- Si on a $f(x) = o(x^2)$, cela signifie que $\forall \varepsilon > 0$, il existe un voisinage étoilé de rayon $\delta > 0$ tel que pour tout point x de ce voisinage, on a $|f(x)| < \varepsilon|x^2|$.

En ne regardant que la partie $]0, 0 + \delta]$ du voisinage étoilé, on peut donc en conclure qu'il existe $x_{\max} > 0$ tel que $\forall x \in]0, x_{\max}]$, on a :

$$\frac{|f(x)|}{x^2} < \varepsilon \quad \text{ou encore} \quad \frac{|o(x^2)|}{x^2} < \varepsilon.$$

Taylor

$$f(x) = P_h(x) + R(x)$$

$$\hookrightarrow n=1 : f(x) = f(a) + f'(a)(x-a) + \frac{f''(a)}{2}(x-a)^2 + \dots + \frac{f^{(h)}(a)}{h!}(x-a)^h + \frac{f^{(h+1)}(c)}{(h+1)!}(x-a)^{h+1} \quad \text{avec } c \text{ entre } a \text{ et } x$$

$$\hookrightarrow \begin{matrix} f(x) = e^x \\ a=0 \\ h=3 \end{matrix} \rightarrow e^x = 1 + x + \frac{x^2}{2} + \frac{x^3}{3} + \frac{e^c}{24} x^4 \quad \text{avec } c \text{ entre } a \text{ et } x$$

Que peut-on dire sur le terme d'erreur ?

$$\forall \varepsilon > 0, \exists \delta > 0 : \forall x \in E, x \in V_g^*(a) \Rightarrow |f(x)| \leq \varepsilon |g(x)|$$

$$\hookrightarrow f(x) = o(g(x)) : "f(x) \text{ est n\u00e9gligeable par rapport \u00e0 } g(x)"$$

$$\hookrightarrow \dots \dots \dots \Rightarrow \left| \frac{f(x)}{g(x)} - 0 \right| \leq \varepsilon$$



$$\lim_{x \rightarrow a} \frac{f(x)}{g(x)} = 0$$

$$\hookrightarrow \text{Pour Taylor, on a impos\u00e9 : } \lim_{x \rightarrow a} \frac{f(x) - P_h(x)}{(x-a)^h} = 0$$

$$"f(x) - P_h(x) \text{ doit \u00eatre n\u00e9gligeable par rapport \u00e0 } (x-a)^h"$$

$$\hookrightarrow e^x - \left(1 + x + \frac{x^2}{2} + \frac{x^3}{6}\right) :$$


$$R(x) = \frac{f^{(h+1)}(c)}{(h+1)!} (x-a)^{h+1} = o((x-a)^h)$$

Exemple

* $x^2 = o(x)$ " x^2 est négligeable autour de $0=0$ par rapport à x "

↳ Il est tjs possible de trouver un voisinage autour de $a=0$

tel que $|x^2| < \varepsilon |x|$ avec $\varepsilon > 0$



$$\Rightarrow -\varepsilon|x| \leq o(x) \leq \varepsilon|x|$$

$$m \geq 2$$

$$\text{Notation: } x = a + d \quad \begin{matrix} \in \mathbb{R}^n & \in \mathbb{R}^n & \in \mathbb{R}^n \\ a & d & d \end{matrix}$$

$$\hookrightarrow h=1: f(x) = f(a) + \nabla f(a)^T \cdot (x-a) + o(|x-a|)$$

$$\hookrightarrow f(a+d) = f(a) + d \nabla f(a)^T d + o(|d|)$$

$$\hookrightarrow h=2: f(x) = f(a) + \nabla f(a)^T (x-a) + \frac{1}{2} (x-a)^T \nabla^2 f(a) (x-a) + o(|x-a|^3)$$

$$\hookrightarrow f(a+d) = f(a) + d \nabla f(a)^T d + \frac{d^2}{2} d^T \nabla^2 f(a) d + o(|d|^3)$$

Exemple

$$\text{Seit } f(x_1, x_2) = ((x_1 + x_2)^2 - 1) \quad a = \left(\frac{1}{4}; \frac{1}{4}\right) \quad d = (1, 1) \quad h=2$$

$$\hookrightarrow \nabla f(x) = \begin{pmatrix} 2(x_1 + x_2)^2 - 1 \cdot 2(x_1 + x_2) \\ 2(x_1 + x_2)^2 - 1 \cdot 2(x_1 + x_2) \end{pmatrix}$$


$$\hookrightarrow \nabla^2 f(x) = \begin{pmatrix} 4(x_1 + x_2) & 4(x_1 + x_2) \\ 4(x_1 + x_2) & 4(x_1 + x_2) \end{pmatrix}$$

$$\begin{aligned} \hookrightarrow P_h(x) &= f(a) + d \nabla f(a)^T d + \frac{d^2}{2} d^T \nabla^2 f(a) d \\ &= \left(\left(\frac{1}{4} + \frac{1}{4}\right)^2 - 1\right) + d \begin{pmatrix} -\frac{3}{2} & -\frac{3}{2} \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} + \frac{d^2}{2} (1, 1) \begin{pmatrix} -1 & -1 \\ -1 & -1 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} \end{aligned}$$

$$= \frac{9}{16} - 3d - 2d^2$$

$$\hookrightarrow f(a+d) = \frac{9}{16} - 3d - 2d^2 + o(d^2)$$

Continuité au sens de Lipschitz



Une fonction f est Lipschitz continue s'il existe une constante $L > 0$ telle que $\forall x_1, x_2$, on a

$$|f(x_1) - f(x_2)| \leq L |x_1 - x_2|.$$

Une fonction dont la dérivée est Lipschitz continue avec une constante L est appelée une fonction L -smooth.

Plan

- 1 Introduction au cours
- 2 Définitions et rappels
- 3 Globalement, il n'y a pas d'espoir
 - Minimas globaux, locaux, et stricts
 - Minimum global inaccessible en général
- 4 Introduction aux conditions d'optimalité

Minimas globaux, locaux, et stricts pour $f : \mathbb{R}^n \rightarrow \mathbb{R}$

$$\min_x f(x) \text{ tel que } x \in X$$


- $x^* \in X$ est un minimum **global** ssi

$$f(x^*) \leq f(x) \quad \forall x \in X$$

- $x^* \in X$ est un minimum **local** ssi

$$\exists \delta > 0 : \forall x \in X, \|x - x^*\| \leq \delta \Rightarrow f(x^*) \leq f(x)$$

Exemple : $f(x) = \frac{-5}{6}x^3 + \frac{7}{2}x^2 - \frac{11}{3}x + 3$



- $x^* \in X$ est un **minimum local strict** ssi

$$\exists \delta > 0 : \forall x \in X, 0 < \|x - x^*\| \leq \delta \Rightarrow f(x^*) < f(x)$$

Une fonction avec un minimum global compliqué à trouver

Afin de montrer que la recherche du minimum global pour **n'importe quel problème** est compliquée, nous allons calculer une **borne inférieure** sur le nombre de points à évaluer.

Cet exemple est illustratif, nous pouvons donc nous fixer quelques hypothèses :


- La fonction $f : \mathbb{R}^n \rightarrow \mathbb{R}$ est Lipschitz continue avec une constante L .
- La borne inférieure calculée sera pour des méthodes d'**ordre 0** (aucune information sur les dérivées n'est utilisée).
- L'espace de travail est la boule $([0, 1])^n$.

La fonction utilisée est la **pire** possible :

pour n'importe quel point x évalué, la réponse est la même : $f(x) = 0$.

Afin de n'avoir qu'une erreur ε par rapport au minimum global ($f(x) - f^* \leq \varepsilon$), quel doit être le nombre p de points évalués ?

Exemple pour $n = 1$:



Une fonction avec un minimum global compliqué à trouver

Pour une fonction à n variables, on trouve :

$$\left(\frac{L}{2\varepsilon}\right)^n.$$

Exemple.


- Fonction à $n = 10$ variables et $L = 2$.
- On souhaite une précision $\varepsilon = 0.001$

$$\left(\frac{L}{2\varepsilon}\right)^n = \left(\frac{2}{2 * 0.001}\right)^{10} = 10^{30} \text{ évaluations.}$$

Avec 10^{12} évaluations/seconde, cela représente 32.000.000.000 années.

- C'est sans espoir ... de découvrir une méthode permettant de trouver le minimum global de tous les problèmes !
- Un algorithme universel n'existe pas. Il est cependant possible de résoudre efficacement toute une série de problèmes à l'aide de méthodes dédiées.

« Il n'y a pas d'espoir »



def $f(x)$:

retourne valeur de f en x

$p+1$ points $\rightarrow$ Intervalles de longueur $\frac{1}{p}$



$$\hookrightarrow \frac{1}{p} \leq \frac{2E}{L} \rightarrow p \geq \frac{L}{2E}$$

$$\hookrightarrow p \geq \left\lceil \frac{L}{2E} \right\rceil$$

Plan

- 1 Introduction au cours
- 2 Définitions et rappels
- 3 Globalement, il n'y a pas d'espoir
- 4 Introduction aux conditions d'optimalité
 - Rappels sur les conditions nécessaires et suffisantes
 - Pourquoi des conditions d'optimalité en optimisation ?
 - Conditions d'optimalité en optimisation

Conditions nécessaires et suffisantes

Si P et Q sont des propriétés

$$P \Rightarrow Q$$

- Q est une condition nécessaire à P
- P est une condition suffisante à Q

Lorsqu'on a l'implication $P \Rightarrow Q$, il est équivalent d'écrire la **contraposée** :

$$\neg Q \Rightarrow \neg P$$

$$P \Leftrightarrow Q$$

- P et Q sont des conditions nécessaires et suffisantes