

MARO 036 - Optimisation Non-Linéaire

Arnaud Vandaele

Faculté Polytechnique
Service **MA**thématique et **R**echerche **O**opérationnelle



Année académique 2024-2025

Séance 5 :

Vitesse de convergence, Coordinate Descent et Recherche
unidimensionnelle

Séance 5 – Vitesse de convergence, Coordinate Descent et Recherche unidimensionnelle

Tables des matières

- 1 Introduction
- 2 Vitesse de convergence
- 3 Coordinate Descent
- 4 Recherche unidimensionnelle
- 5 Condition suffisante de convergence

Plan

- 1 Introduction
- 2 Vitesse de convergence
- 3 Coordinate Descent
- 4 Recherche unidimensionnelle
- 5 Condition suffisante de convergence

Méthodes pour l'optimisation non-linéaire

Jusque maintenant : modèles (conditions d'optimalité et problèmes convexes)

Maintenant, mise en oeuvre de méthodes numériques pour la résolution de :

$$\min_{x \in \mathbb{R}^n} f(x) \text{ tel que } x \in X.$$

Les méthodes numériques présentées dans ce cours sont itératives :
on démarre d'une solution initiale et on tente de l'**améliorer progressivement**
(exemple : l'algorithme du simplexe est une méthode itérative)

- 1 Choix d'un point initial : $x^{(0)}$
- 2 For $k = 1, 2, \dots, K$
 - A partir de $x^{(k-1)}$, trouver un nouveau point $x^{(k)}$
souvent tel que $f(x^{(k)}) \leq f(x^{(k-1)})$ (monotonicité)
- 3 Solution finale : $x^{(K)}$

Il existe **beaucoup** de méthodes itératives pour l'optimisation et une classification objective est difficile. Nous aborderons les plus connues dans la suite de ce cours.

Questions à se poser : est-ce que ces méthodes convergent? Vers quoi? (un point stationnaire? un minimum local?) A quelle vitesse? Sous quelles conditions ? etc.

Les méthodes itératives en optimisation partagent souvent ce

framework :

$$x^{(k+1)} = \underbrace{x^{(k)}}_{\substack{\in \mathbb{R}^n \\ \text{"itération"}}} + \underbrace{\alpha^{(k)}}_{\substack{\in \mathbb{R}^m \\ \text{"pas"}}} \underbrace{d^{(k)}}_{\substack{\in \mathbb{R} \\ \text{"direction"}}}$$

Plan

1 Introduction

2 Vitesse de convergence

- Convergence linéaire et taux de convergence
- Convergence superlinéaire et ordre de convergence

3 Coordinate Descent

4 Recherche unidimensionnelle

5 Condition suffisante de convergence

Convergence linéaire et taux de convergence

Soit la suite $\{x^{(0)}, x^{(1)}, x^{(2)}, \dots\}$ convergeant vers x^* .

A quelle vitesse cette suite s'approche-t-elle de x^* ?

Pour amener une réponse à cette question, introduisons d'abord la notion de **taux de convergence** μ .

S'il existe un nombre $\mu \in]0, 1[$ tel que

$$\lim_{k \rightarrow \infty} \frac{\|x^{(k+1)} - x^*\|}{\|x^{(k)} - x^*\|} = \mu,$$

alors on dit que la **suite converge linéairement** avec un **taux** μ .

Cela signifie que, pour k suffisamment grand, on a

$$\|x^{(k+1)} - x^*\| \leq \mu \|x^{(k)} - x^*\|.$$

La quantité $\|x^{(k)} - x^*\|$ est l'**erreur** e_k de l'itéré k par rapport à la solution recherchée x^* . La propriété de convergence linéaire peut se réécrire :

$$e_{k+1} \leq \mu e_k.$$

Convergence linéaire : illustration

A partir de la propriété de convergence linéaire $e_{k+1} \leq \mu e_k$, on en déduit que


$$\log(e_k) \approx k \log(\mu) + \log(e_0),$$

qui est de la forme $\log(e_k) \approx ak + b$, d'où le nom de convergence linéaire.

Exemple.

Soit l'itéré initial $x^{(0)} = 2.1$ et la suite suivante convergeant vers $x^* = 2 + \frac{\sqrt{2}}{2} \approx 2.707106781186$:

$$x^{(k+1)} = -(x^{(k)})^2 + 5x^{(k)} - 3.5.$$



k	$x^{(k)}$	$e_k = x^{(k)} - x^* $	$e_k / e_{k-1} \approx \mu$
0	2.1	6.0710678118654e - 01	
1	2.59	1.1710678118654e - 01	0.192893218813452
2	2.7419	3.4793218813453e - 02	0.297106781186555
3	2.69148439	1.5622391186545e - 02	0.449006781186490
4	2.7133337283863	6.2269471997806e - 03	0.398591171186609
5	2.7044887203327	2.6180608537584e - 03	0.420440509572765
6	2.7081843632566	1.0775820701116e - 03	0.411595501519640
7	2.7066592708954	4.4751029112610e - 04	0.415291144441310
8	2.7072919457529	1.8516456642725e - 04	0.413766052086330
9	2.7070300492259	7.6731960601428e - 05	0.414398726937717
10	2.7071385587175	3.1777530955956e - 05	0.414136830427411
11	2.7070936174924	1.3163694111639e - 05	0.414245339887626

Convergence superlinéaire et ordre de convergence

Que dire quand la limite ci-dessous vaut 0 ?

$$\lim_{k \rightarrow \infty} \frac{\|x^{(k+1)} - x^*\|}{\|x^{(k)} - x^*\|} = 0.$$

- La convergence est alors dite **superlinéaire**.
- Pour distinguer les suites qui convergent superlinéairement, on introduit une notion supplémentaire : l'ordre de convergence p .

S'il existe un nombre $p > 1$ et une constante $C > 0$ tels que

$$\lim_{k \rightarrow \infty} \frac{\|x^{(k+1)} - x^*\|}{\|x^{(k)} - x^*\|^p} = C,$$

alors p est appelé l'ordre de convergence de la suite et C est la constante d'erreur. Cela signifie que, pour k suffisamment grand, on a

$$\|x^{(k+1)} - x^*\| \leq C \|x^{(k)} - x^*\|^p.$$

(convergence **quadratique** si $p = 2$, convergence **cubique** si $p = 3, \dots$)

Le taux de convergence μ et l'ordre de convergence p sont deux nombres utilisés pour décrire la vitesse de différents types de convergence. Une suite a soit un taux de convergence **si la convergence est linéaire**, soit un ordre de convergence **si la convergence est superlinéaire**, et non les deux. Cependant, plus le taux est bas ou plus l'ordre est élevé, plus la convergence est rapide.

Convergence quadratique : illustration

A partir de la propriété de convergence superlinéaire $e_k \leq Ce_k^{p-1}$, on en déduit


$$\log(e_k) \approx p \log(e_{k-1}) + \log(C),$$

qui donne $\log(e_k) \approx 2 \log(e_{k-1}) + \log(C)$ pour une convergence quadratique.

Exemple.

Soit l'itéré initial $x^{(0)} = 1$ et la suite suivante convergeant vers $x^* \approx 0.8526055020137$:

$$x^{(k+1)} = \frac{(x^{(k)})^2 + 2e^{-x^{(k)}}}{x^{(k)} + 1}.$$




k	$x^{(k)}$	$e_k = x^{(k)} - x^* $	e_k / e_{k-1}	$e_k / (e_{k-1})^2$
0	1	0.14739449798627		
1	0.8678794411714	0.01527393915771	0.103626250412272	0.703053722004751
2	0.8527833734164	0.00017787140268	0.011645417783046	0.762437093849651
3	0.8526055263689	0.00000002435519	0.000136925869806	0.769802608737066
4	0.8526055020137	0.00000000000000	0.000000013675394	0.561497992509584

Pour une suite convergeant quadratiquement, on remarque que le nombre de décimales correctes double approximativement à chaque itération.

Vitesse de convergence d'une suite : exemples

Différence de comportement entre différents types de convergence



Plan

- 1 Introduction
- 2 Vitesse de convergence
- 3 Coordinate Descent
 - Schéma général
 - Les variations possibles
 - Propriétés et convergence
 - Illustration
- 4 Recherche unidimensionnelle
- 5 Condition suffisante de convergence

Coordinate Descent (CD)

Une méthode très simple conceptuellement

A partir d'un itéré initial $x^{(0)}$, cette méthode consiste à minimiser successivement chaque variable du problème **séparément** en gardant les autres variables fixées :

Entrées : itéré initial $x^{(0)}$

Initialisation : $k = 1$

For $k = 1, 2, \dots$

- Choix d'un indice i_k
- Mise à jour de la coordonnée i_k :

$$x_j^{(k)} = \begin{cases} \text{Update}(f, x^{(k-1)}, i_k) & \text{si } j = i_k \\ x_j^{(k-1)} & \text{si } j \neq i_k \end{cases}$$

L'opération $\text{Update}(f, x^{(k-1)}, i_k)$ est elle-même un problème d'optimisation : elle consiste à optimiser f uniquement suivant la variable i_k . Cependant, ce sous-problème possède **une seule variable**.

CD est un framework général et les différentes variations proviennent :

- du choix de l'indice i_k
- de comment est effectuée la mise à jour $\text{Update}(f, x^{(k-1)}, i_k)$

Coordinate Descent (CD) : variations

Choisir l'indice i_k

- Sans utiliser le gradient
 - cyclique : $i_k = 1, 2, 3, \dots, n, 1, 2, 3, \dots$
 - double balayage : $i_k = 1, 2, 3, \dots, n, n-1, n-2, \dots, 1, 2, 3, \dots$
 - distribution uniforme : chaque indice est choisi avec une proba $p_i = \frac{1}{n}$
 - cyclique aléatoire : à chaque cycle, les variables sont triées aléatoirement
- En utilisant le gradient (choisir les coordonnées "importantes")
 - Gauss-Southwell : $i_k = \arg \max_i |\nabla_i f(x^{(k-1)})|$
 - GS normalisé par la constante de Lipschitz : $i_k = \arg \max_i \frac{|\nabla_i f(x^{(k-1)})|}{\sqrt{L_i}}$

La mise à jour $Update(f, x^{(k-1)}, i_k)$

- Mise à jour exacte si le problème à une variable est facile à résoudre
- Mise à jour approximative si le problème à une variable est difficile

Propriétés et convergence

- Méthode **simple** et **intuitive** relativement facile à implémenter, à condition de pouvoir minimiser les fonctions à une variable considérés
- Convergence souvent très **lente** en pratique par rapport à d'autres méthodes (exemple : certaines fonctions quadratiques $\rightarrow$ très petits pas ; p.ex. souvent en pratique n pas coordonnées $\approx$ un pas de gradient)
- On peut également optimiser plus qu'une variable à la fois, on parle alors de *Block coordinate descent (BCD)*

Convergence. Si les hypothèses suivantes sont vérifiées :

- 1 f différentiable sur son domaine X
- 2 la valeur calculée t^* lors de la mise à jour de chaque sous problème à une variable $f(x_1, \dots, t, \dots, x_n)$ est un minimum unique
- 3 f est monotone décroissante de x_i à t^*

alors : les itérations $x^{(k)}$ convergent vers un point stationnaire.

(les conditions 2 et 3 sont satisfaites pour f strictement convexe)

Illustration dans un cas respectant les conditions suffisantes

$f(x_1, x_2) = 5x_1^2 - 6x_1x_2 + 5x_2^2$ à partir de $x^{(0)} = (-\frac{1}{2}, -1)$





Illustration dans un cas ne respectant pas les cond. suff.

$f(x_1, x_2) = |x_1 + x_2| + 3|x_2 - x_1|$ à partir de $x^{(0)} = (-2, -2)$



L'exemple ci-dessus montre qu'il est possible de rester bloqué à un point non stationnaire si les courbes de niveau d'une fonction ne sont pas smooth. Au point $(-2, -2)$, un mouvement dans la direction d'un des deux axes augmentera la valeur de la fonction objectif, de sorte que l'algorithme ne fera aucun pas.

Implémentation

Implémentez une méthode de coordinate descent pour

- la fonction

$$f(x_1, x_2) = 5x_1^2 - 6x_1x_2 + 5x_2^2 - 4x_1 + 3x_2,$$

- une fonction quadratique dans le cas général

$$f(x) = \frac{1}{2}x^T Qx - c^T x + p,$$

- le problème de moindres carrés

$$f(x) = \|Ax - b\|_2^2.$$

$$\min_x Sx_1^2 - 6x_1x_2 + 5x_2^2 - 4x_1 + 3x_2$$

$$\hookrightarrow \begin{pmatrix} 1 \\ 0 \end{pmatrix}$$

$$\hookrightarrow \begin{pmatrix} 0 \\ 1 \end{pmatrix}$$

Descente de coordonnées

* $d^{(k)} = \begin{pmatrix} 0 \\ 1 \\ 0 \\ 0 \\ 0 \\ 0 \end{pmatrix} \rightarrow$ direction du mouvement // aux axes

Si les CS. sont satisfaites, on converge en un point en $\nabla f(x) = 0$

$\hookrightarrow$ On optimise une variable à la fois!

* On essaie de calculer le min exactement (quand c'est possible) le long de la direction

$\hookrightarrow$ Au 1^{ère} itération, on longe suivant $\begin{pmatrix} 0 \\ 1 \end{pmatrix}$

$$\hookrightarrow x^{(0)} = \begin{pmatrix} -1/2 \\ -1 \end{pmatrix}$$

$$\hookrightarrow f(x^{(0)} + \alpha \begin{pmatrix} 0 \\ 1 \end{pmatrix}) = f\left(\begin{pmatrix} -1/2 \\ -1 \end{pmatrix} + \alpha \begin{pmatrix} 0 \\ 1 \end{pmatrix}\right) = f\left(\begin{pmatrix} -1/2 \\ -1 + \alpha \end{pmatrix}\right) = \dots = 0 \Leftrightarrow \alpha = \frac{3}{10}$$

$\hookrightarrow$ On fixe toutes les variables sauf une : $f(x) = 5x^2 - 6x(x_2) + 5(x_2)^2 - 4x + 3(x_2)$

$$\hookrightarrow f'(x) = 10x - 6x_2 - 4 = 0 \Leftrightarrow x = \frac{6x_2 + 4}{10}$$

$\hookrightarrow$ On optimise x_2 : $f(x) = 5x_1^2 - 6x_1x_2 + 5x_2^2 - 4x_1 + 3x_2$

$$\hookrightarrow f'(x) = -6x_1 + 10x_2 + 3 = 0 \Leftrightarrow x_2 = \frac{6x_1 - 3}{10}$$

$$f(x) = \frac{1}{2} x^T Q x - c^T x + p,$$

$$f(x_2) = \frac{1}{2} (x_1, x_2, x_3) \begin{pmatrix} q_{11} & q_{12} & q_{13} \\ q_{21} & q_{22} & q_{23} \\ q_{31} & q_{32} & q_{33} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} - (c_1, c_2, c_3) \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} + p$$

$$= x_2^2 \left(\frac{q_{22}}{2} \right) + x_1 x_2 \left(\frac{q_{12}}{2} + \frac{q_{21}}{2} \right) + x_2 x_3 \left(\frac{q_{23}}{2} + \frac{q_{32}}{2} \right) - c_2 x_2 + x_2^0 (\dots)$$

$$\hookrightarrow f'(x_2) = q_{22} x_2 + \frac{1}{2} x_1 (q_{12} + q_{21}) + \frac{1}{2} x_3 (q_{23} + q_{32}) - c_2 = 0$$

$$\hookrightarrow x_2 = \frac{1}{q_{22}} \left(c_2 - \frac{1}{2} x_1 (q_{12} + q_{21}) - \frac{1}{2} x_3 (q_{23} + q_{32}) \right) \stackrel{\text{↗ quand Q est symétrique}}{=} \frac{1}{q_{22}} (c_2 - q_{21} x_1 - q_{23} x_3)$$

$$\hookrightarrow x_i^* = \frac{c_i - \sum_{j=1}^n q_{ij} x_j + q_{ii} x_i}{q_{ii}} = x_i - \frac{\sum_{j=1}^n q_{ij} x_j}{q_{ii}}$$

Plan

- 1 Introduction
- 2 Vitesse de convergence
- 3 Coordinate Descent
- 4 Recherche unidimensionnelle
 - Schéma général
 - Rappels : directions de descente
 - Présentation de la méthode du gradient
 - Dans le cas d'une fonction quadratique
- 5 Condition suffisante de convergence

Recherche en ligne (unidimensionnelle) (*line search*)

Un grand nombre de méthodes pour l'optimisation **sans contraintes**,

$$\min_{x \in \mathbb{R}^n} f(x)$$

où f est suffisamment différentiable mais pas nécessairement convexe,
sont basées sur une stratégie de **recherche en ligne** :

1 Initialisation : un point de départ $x^{(0)} \in \mathbb{R}^n$ et un indice $k := 0$

2 Tant qu'on n'est pas suffisamment proche d'un minimum

1 Trouver une **direction de recherche** $d^{(k)} \in \mathbb{R}^n$


2 Trouver une **longueur de pas** $\alpha^{(k)}$ qui **minimise**

$$\min_{\alpha > 0} g(\alpha) = f(x^{(k)} + \alpha d^{(k)})$$

Mettre à jour $x^{(k+1)} := x^{(k)} + \alpha^{(k)} d^{(k)}$ puis $k := k + 1$

Mais, attention, cette stratégie est itérative :

- sous quelles conditions la méthode converge ?
- à quelle vitesse converge-t-on vers le point identifié ?
- que peut-on dire sur le point identifié par la méthode ?



Lorsqu'on se trouve au point $x^{(k)}$,

- **quelle direction $d^{(k)}$ choisir ?** une direction de descente!
- **quel pas $\alpha^{(k)}$ choisir le long de $d^{(k)}$?**

(Rappels) Direction de descente : définition

Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}$. Une direction d est une direction de descente en un point x si :

$$d^T \nabla f(x) < 0,$$

autrement dit, lorsque la dérivée directionnelle de f au point x dans la direction d est négative. Cela signifie que la fonction est décroissante dans la direction d .


Théorème.

Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}$. Si d est une direction de descente en un point x , alors $\exists \alpha_{\max} > 0$:

$$f(x + \alpha d) < f(x), \quad \forall \alpha \in]0, \alpha_{\max}].$$

Illustration.

Pour la fonction $f(x_1, x_2) = (x_1 + x_2)^4 - 2(x_1 + x_2)^2 + 1$ au point $x = (\frac{1}{4}, \frac{1}{4})$ dans la direction $d = (1, 1)^T$, on a $f(x + \alpha d) = ((0.5 + 2\alpha)^2 - 1)^2$.



Dans cet exemple, $\alpha_{\max} = 0.411438$.

Méthode du gradient

$$d^{(h)} = -\nabla f(x^{(h)})$$

$$\alpha^{(h)} =$$

Méthode du gradient/de la plus forte pente

A l'itéré k , quel choix de direction $d^{(k)}$?

Un choix très populaire est la **direction opposée au gradient** :

$$d^{(k)} = -\nabla f(x^{(k)}).$$

- Cette direction est une direction de descente, en effet :


$$d^{(k)T} \nabla f(x^{(k)}) = -\nabla f(x^{(k)})^T \nabla f(x^{(k)}) = -\|\nabla f(x^{(k)})\|_2^2 < 0.$$

Etant donné $x^{(0)}$, les itérés suivants sont obtenus par :

$$x^{(k)} = x^{(k-1)} - \alpha^{(k-1)} \nabla f(x^{(k-1)}).$$

Abordons d'abord un cas facile : f quadratique

$f(x) = \frac{1}{2}x^T Qx - c^T x + p$ avec Q symétrique définie positive



- Comme les n val. propres de Q sont positives $\lambda_{\max}(Q) \geq \dots \geq \lambda_{\min}(Q) > 0$,
 - f est **L -smooth** avec $L = \lambda_{\max}(Q)$.
 - f est **strictement convexe** avec $\mu = \lambda_{\min}(Q)$.
- Comme Q est symétrique, son conditionnement est donné par :

$$\kappa(Q) = \frac{\lambda_{\max}(Q)}{\lambda_{\min}(Q)} = \frac{L}{\mu}.$$

Méthode du gradient pour une fonction quadratique

Pour une fonction quadratique $f(x) = \frac{1}{2}x^T Qx - c^T x + p$,

- la direction est $d^{(k)} = -\nabla f(x^{(k)}) = -(Qx^{(k)} - c) = c - Qx^{(k)}$.
- le pas optimal peut être calculé exactement à chaque itération :

$$\alpha^{(k)*} = \frac{-d^{(k)T} \nabla f(x^{(k)})}{d^{(k)T} Q d^{(k)}} = \frac{\|\nabla f(x^{(k)})\|_2^2}{\nabla f(x^{(k)})^T Q \nabla f(x^{(k)})}.$$

Algorithme détaillé :

Entrées : Q , c et $x^{(0)}$

Initialisation : $k = 0$, et $d^{(0)} = -(Qx^{(0)} - c)$

Itérations à répéter :


1. Calcul du pas : $\alpha^{(k)} = \frac{d^{(k)T} d^{(k)}}{d^{(k)T} Q d^{(k)}} \quad \mathcal{O}(n^2) \rightarrow \mathcal{O}(n) \text{ si } Q \text{ est sparse}$
2. Itéré suivant : $x^{(k+1)} = x^{(k)} + \alpha^{(k)} d^{(k)} \quad \mathcal{O}(n)$
3. Nouvelle direction : $d^{(k+1)} = -(Qx^{(k+1)} - c) \quad \mathcal{O}(n^2) \rightarrow \mathcal{O}(n) \text{ si } Q \text{ est sparse}$
4. $k = k + 1$

Coût total d'une itération :

$\mathcal{O}(n^2)$ dans le cas général et $\mathcal{O}(n)$ dans le cas d'une matrice Q sparse.

Illustration

Application de la méthode du gradient à $f(x_1, x_2) = \frac{1}{2}x_1^2 + \frac{9}{2}x_2^2$ à partir de $x_0 = (9 \ 1)^T$.



Pourquoi des zigzags ?


Soit $g(\alpha) = f(x^{(k)} + \alpha d^{(k)})$. On a alors $g'(\alpha) = d^{(k)T} \nabla f(x^{(k)} + \alpha d^{(k)})$.

Si on utilise le meilleur α , cette dérivée vaut 0 et cela implique :

$$d^{(k)T} \nabla f(x^{(k+1)}) = 0 \Rightarrow \nabla f(x^{(k)})^T \nabla f(x^{(k+1)}) = 0.$$

Influence du conditionnement $\kappa(Q)$

Les directions $d^{(k)}$ et $d^{(k+1)}$ sont orthogonales (voir explications au slide 25) :



Ce nombre d'itérations à effectuer est accentué par le conditionnement $\kappa(Q)$.

On peut montrer que

$$\left\| x^{(k+1)} - x^* \right\|_Q \leq \left(\frac{\kappa(Q) - 1}{\kappa(Q) + 1} \right)^k \left\| x^{(0)} - x^* \right\|_Q.$$

Plan

- 1 Introduction
- 2 Vitesse de convergence
- 3 Coordinate Descent
- 4 Recherche unidimensionnelle
- 5 Condition suffisante de convergence

Condition suffisante de convergence vers un point stationnaire

Pour une fonction f **continûment différentiable** et **bornée inférieurement**, si on a, pour une valeur $M > 0$,

$$f(x^{(k+1)}) \leq f(x^{(k)}) - M \left\| \nabla f(x^{(k)}) \right\|^2,$$

alors

$$\lim_{k \rightarrow \infty} \left\| \nabla f(x^{(k)}) \right\| = 0.$$

- Cela signifie que les itérés $x^{(k)}$ convergent vers un point stationnaire.
- On parle parfois de **convergence globale** pour les algorithmes convergent quel que soit le point de départ. Il ne faut pas confondre convergence globale et minimum global : un algorithme peut être globalement convergent sans nécessairement converger vers le minimum global.
- Il n'est pas si restrictif d'imposer à f d'être bornée inférieurement : si ce n'est pas le cas, le problème d'optimisation est alors mal défini .

Preuve

$$\lim_{h \rightarrow +\infty} f(x^{(h)}) - f(x^{(h+1)}) \geq \lim_{h \rightarrow +\infty} M \lim_{h \rightarrow +\infty} \|\nabla f(x^{(h)})\|^2 \geq 0$$

$\lim_{h \rightarrow +\infty} = 0$ (under the first term)
 $\lim_{h \rightarrow +\infty} = 0$ (under the second term)
 $\lim_{h \rightarrow +\infty} = 0$ (under the third term)

(grâce à l'hypothèse que f est borné inférieurement)

$\Rightarrow \lim_{h \rightarrow +\infty} \|\nabla f(x^{(h)})\| = 0 \rightarrow$ on converge en un point stationnaire

