

MARO 036 - Optimisation Non-Linéaire

Arnaud Vandaele

Faculté Polytechnique
Service MATHématique et Recherche Opérationnelle



Année académique 2024-2025

Séance 6 :

Recherche en ligne : conditions de Wolfe, analyse de la méthode du gradient et gradient accéléré

Séance 6 – Recherche en ligne : conditions de Wolfe, analyse de la méthode du gradient et gradient accéléré

Tables des matières

- 1 Conditions de Wolfe
- 2 Analyse de la méthode du gradient
- 3 Méthode du gradient accéléré
- 4 Annexe : notations

Plan

1 Conditions de Wolfe

- Rappels : directions de descente
- Schéma général
- Problématique du choix du pas
- Première condition de Wolfe $W1$: décroissance suffisante
- Deuxième condition de Wolfe $W2$: progrès suffisant
- Interprétation et existence
- Algorithme pour trouver le pas
- Condition suffisante de convergence

2 Analyse de la méthode du gradient

3 Méthode du gradient accéléré

4 Annexe : notations

(Rappels) Direction de descente : définition

Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}$. Une direction d est une direction de descente en un point x si :

$$d^T \nabla f(x) < 0,$$

autrement dit, lorsque la dérivée directionnelle de f au point x dans la direction d est négative. Cela signifie que la fonction est décroissante dans la direction d .


Théorème.

Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}$. Si d est une direction de descente en un point x , alors $\exists \alpha_{\max} > 0$:

$$f(x + \alpha d) < f(x), \quad \forall \alpha \in]0, \alpha_{\max}].$$

Illustration.

Pour la fonction $f(x_1, x_2) = (x_1 + x_2)^4 - 2(x_1 + x_2)^2 + 1$ au point $x = (\frac{1}{4}, \frac{1}{4})$ dans la direction $d = (1, 1)^T$, on a $f(x + \alpha d) = ((0.5 + 2\alpha)^2 - 1)^2$.



Dans cet exemple, $\alpha_{\max} = 0.411438$.

Recherche en ligne (unidimensionnelle) (*line search*)

Un grand nombre de méthodes pour l'optimisation **sans contraintes**,

$$\min_{x \in \mathbb{R}^n} f(x)$$

où f est suffisamment différentiable mais pas nécessairement convexe, sont basées sur une stratégie de **recherche en ligne** :

1 Initialisation : un point de départ $x^{(0)} \in \mathbb{R}^n$ et un indice $k := 0$

2 Tant qu'on n'est pas suffisamment proche d'un minimum


1 Trouver une **direction de recherche** $d^{(k)} \in \mathbb{R}^n$

2 Trouver une **longueur de pas** $\alpha^{(k)}$ qui **minimise**

$$\min_{\alpha > 0} g(\alpha) = f(x^{(k)} + \alpha d^{(k)})$$

Mettre à jour $x^{(k+1)} := x^{(k)} + \alpha^{(k)} d^{(k)}$ puis $k := k + 1$

Ces méthodes n'ont pour vocation que d'identifier un minimum **local** (à moins d'avoir affaire à une problème d'optimisation convexe)




Lorsqu'on se trouve au point $x^{(k)}$,

- **quelle direction $d^{(k)}$ choisir ?** une direction de descente!
- **quel pas $\alpha^{(k)}$ choisir le long de $d^{(k)}$?** (ce cours-ci)

Choix du pas α

En l'itéré x et étant donné une direction de descente d , comment trouver le pas α ?



- Calculer la longueur de pas qui minimise **exactement** $g(\alpha)$ est possible dans certains cas, par exemple quand $f = \frac{1}{2}x^T Ax - b^T x + c$:

$$\alpha^* = \frac{-d^{(k)T} (Ax^{(k)} - b)}{d^{(k)T} A d^{(k)}}.$$


- Dans la plupart des cas, calculer la longueur exacte du pas est **couteux** (problème d'optimisation en tant que tel) et inutile si la direction n'est pas bonne.
- Des petits pas devraient être utilisés afin que l'approximation linéaire de la fonction reste valable. Cependant, on désire avancer rapidement et faire des pas plus longs.
- Afin de concilier ces deux objectifs contradictoires, on introduit des conditions à respecter : les conditions de Wolfe. La longueur du pas n'est donc pas optimale mais est **plus facile à calculer**.

Condition de décroissance suffisante


Etant donné un point itéré x et une direction d , on souhaite que le pas α vérifie une certaine décroissance (imposée à l'aide d'un paramètre $\gamma > 0$) :

$$f(x + \alpha d) \leq f(x) - \alpha\gamma.$$

Exemple : $f(x) = \frac{1}{2}x_1^2 + \frac{9}{2}x_2^2$ en l'itéré $(10, 1)$ et $\gamma = 6$



$$\text{pour } d_1 = \begin{pmatrix} \frac{-10}{\sqrt{181}} & \frac{-9}{\sqrt{181}} \end{pmatrix}^T$$



$$\text{pour } d_2 = \begin{pmatrix} \frac{-2}{\sqrt{5}} & \frac{1}{\sqrt{5}} \end{pmatrix}^T$$


Observations :

- γ ne peut pas être constant,
- il doit dépendre de la direction.


Condition de décroissance suffisante

Il est possible de montrer que pour tout $\beta_1 < 1$, il existe $\alpha \in]0, \alpha_{\max}]$ tel que :

$$f(x + \alpha d) < f(x) + \alpha \beta_1 d^T \nabla f(x).$$



d_1 et $\beta_1 = 0.5$



d_1 et $\beta_1 = 0.1$

On choisit donc, avec $0 < \beta_1 < 1$ (typiquement $\beta_1 = 10^{-4}$) :

$$\gamma = -\beta_1 d^T \nabla f(x).$$

Première condition de Wolfe (W1). (également appelée condition d'Armijo-Wolfe)

La fonction f diminue suffisamment en $x^{(k)} + \alpha^{(k)} d^{(k)}$ par rapport à $x^{(k)}$ si, avec $0 < \beta_1 < 1$:

$$f(x^{(k)} + \alpha^{(k)} d^{(k)}) \leq f(x^{(k)}) + \alpha^{(k)} \beta_1 d^{(k)T} \nabla f(x^{(k)}).$$

Inconvénient : cette condition est **toujours** satisfaite lorsque $\alpha \rightarrow 0$, mais n'empêche pas les pas de devenir trop petits $\rightarrow$ il est nécessaire d'introduire une condition supplémentaire.

Condition de progrès suffisant (condition de courbure)

Au point $x^{(k)}$, puisque $d^{(k)}$ est une direction de descente, on a bien $d^{(k)T} \nabla f(x^{(k)}) < 0$. Si on applique le pas optimal dans la direction d_k , on a $g'(\alpha) = 0$, ce qui équivaut à :


$$d^{(k)T} \nabla f(x^{(k)} + \alpha^{(k)} d^{(k)}) = 0.$$

On assiste donc à une **augmentation** de la dérivée directionnelle.

L'idée est donc d'obtenir un pas α tel que cette dérivée augmente suffisamment.

Seconde condition de Wolfe (W2).

Avec $\beta_1 < \beta_2 < 1$ (typiquement $\beta_2 = 0.9$) : $d^{(k)T} \nabla f(x^{(k)} + \alpha^{(k)} d^{(k)}) \geq \beta_2 d^{(k)T} \nabla f(x^{(k)})$.



(en choisissant par exemple $\beta_2 = 0.5$, le pas α doit être tel que $\alpha \geq 1.4687$.)

Condition W2 forte : $\left| d^{(k)T} \nabla f(x^{(k)} + \alpha d^{(k)}) \right| \leq \beta_2 \left| d^{(k)T} \nabla f(x^{(k)}) \right|$.

Interprétation à l'aide de $g(\alpha)$

On sait que pour $g(\alpha) = f(x^{(k)} + \alpha d^{(k)})$, on a

$$g'(\alpha) = d^{(k)T} \nabla f(x^{(k)} + \alpha d^{(k)}).$$

- La condition de **décroissance suffisante** $W1$ impose un taux de décroissance au moins égal à $\beta_1 |g'(0)|$:

$$g(\alpha) \leq g(0) - \alpha \beta_1 |g'(0)|.$$

- La condition de **courbure** $W2$ borne inférieurement $g'(\alpha)$ (c'est-à-dire l'empêche de rester trop négatif)


$$g'(\alpha) \geq \beta_2 g'(0).$$

- La condition forte borne supérieurement $|g'(\alpha)|$, c'est-à-dire empêche $g'(\alpha)$ de trop s'éloigner de zéro :


$$|g'(\alpha)| \leq \beta_2 |g'(0)|.$$

Conditions : illustration $W1+W2$ vs. $W1+W2$ forte

Pas α acceptables pour $W1$ (bleue) et $W2$ (rouge) :



Pas α acceptables pour $W1$ (bleue) et $W2$ forte (rouge) :



Existence

- Si on suppose $f \in C^1$ et
 - $d^{(k)}$ est une direction de **descente**,
 - $g(\alpha) = f(x^{(k)} + \alpha d^{(k)})$ est **bornée** inférieurement pour $\alpha > 0$, et
 - $0 < \beta_1 < \beta_2 < 1$,

alors il existe des **intervalles** de longueurs de pas vérifiant les conditions de Wolfe (et les conditions fortes de Wolfe)

- Si $0 < \beta_2 < \beta_1 < 1$, il est possible qu'aucune valeur α ne vérifie les conditions de Wolfe.
- Il existe des algorithmes de calcul **garantissant** l'obtention d'un de ces points (voir slide suivant)
- Le **minimum** le long de la direction de recherche ne satisfait **pas toujours** aux conditions de Wolfe (d'où le choix de β_1 très petit)
- Ces conditions sont **indépendantes** de l'**échelle**

Algorithme de calcul de α

Méthode permettant de déterminer un pas α vérifiant les conditions W1 et W2.

On se donne : α_0 , $0 < \beta_1 < \beta_2 < 1$ et $\lambda > 1$

- 1 Initialisation : $i = 0$, $\alpha_l = 0$ et $\alpha_r = +\infty$.
- 2 Si α_i vérifie W1 et W2, alors $\alpha^* = \alpha_i$, STOP.
- 3 Si α_i viole W1, alors le pas est trop long.

$$\alpha_r = \alpha_i$$

$$\alpha_{i+1} = \frac{\alpha_l + \alpha_r}{2}$$

- 4 Si α_i ne viole pas W1 mais viole W2, alors le pas est trop court.

$$\alpha_l = \alpha_i$$

$$\alpha_{i+1} = \begin{cases} \frac{\alpha_l + \alpha_r}{2} & \text{si } \alpha_r < +\infty \\ \lambda \alpha_i & \text{sinon.} \end{cases}$$

- 5 $i = i + 1$

Résumé - Conditions de Wolfe

Conditions à respecter pour trouver un "bon" pas $\alpha^{(k)}$ ni trop grand ni trop petit

Première condition de Wolfe (W1). (également appelée condition d'Armijo-Wolfe)

La fonction f diminue suffisamment en $x^{(k)} + \alpha^{(k)}d^{(k)}$ par rapport à $x^{(k)}$ si, avec $0 < \beta_1 < 1$:


$$f(x^{(k)} + \alpha^{(k)}d^{(k)}) \leq f(x^{(k)}) + \alpha^{(k)}\beta_1 d^{(k)T} \nabla f(x^{(k)}).$$

Seconde condition de Wolfe (W2).

Avec $\beta_1 < \beta_2 < 1$ (typiquement $\beta_2 = 0.9$) : $d^{(k)T} \nabla f(x^{(k)} + \alpha^{(k)}d^{(k)}) \geq \beta_2 d^{(k)T} \nabla f(x^{(k)})$.

Condition W2 forte : $|d^{(k)T} \nabla f(x^{(k)} + \alpha d^{(k)})| \leq \beta_2 |d^{(k)T} \nabla f(x^{(k)})|$.

Pas α acceptables pour W1 (bleue) et W2 forte (rouge) :



Condition suffisante de convergence vers un point stationnaire

Pour une fonction f **continûment différentiable** et **bornée inférieurement**, si on a, pour une valeur $M > 0$,

$$f(x^{(k+1)}) \leq f(x^{(k)}) - M \left\| \nabla f(x^{(k)}) \right\|^2,$$

alors

$$\lim_{k \rightarrow \infty} \left\| \nabla f(x^{(k)}) \right\| = 0.$$

- Cela signifie que les itérés $x^{(k)}$ convergent vers un point stationnaire.
- On parle parfois de **convergence globale** pour les algorithmes convergent quel que soit le point de départ. Il ne faut pas confondre convergence globale et minimum global : un algorithme peut être globalement convergent sans nécessairement converger vers le minimum global.
- Il n'est pas si restrictif d'imposer à f d'être bornée inférieurement : si ce n'est pas le cas, le problème d'optimisation est alors mal défini .

Convergence d'une méthode de recherche en ligne générale

Pour une méthode de recherche en ligne **générale**, on définit l'**angle** θ_k entre la direction $d^{(k)}$ et la plus forte pente $-\nabla f(x^{(k)})$ selon

$$\cos \theta_k = -\frac{\nabla f(x^{(k)})^T d^{(k)}}{\|\nabla f(x^{(k)})\| \|d^{(k)}\|}.$$

Condition de Zoutendijk.

Pour une fonction f **continûment différentiable**, **bornée inférieurement**, et avec les hypothèses supplémentaires suivantes :

- 1 f est L -smooth (le gradient ∇f est **Lipschitz** continu :
 $\exists L$ tel que $\|\nabla f(x) - \nabla f(y)\| \leq L \|x - y\|$ pour tout x et y),
- 2 il existe une constante $\delta > 0$ telle que $|\cos \theta_k| \geq \delta$
- 3 **les conditions de Wolfe sont vérifiées**

alors

$$\lim_{k \rightarrow \infty} \|\nabla f(x^{(k)})\| = 0.$$

Géométriquement, Le fait que $|\cos \theta_k| \geq \delta > 0$ signifie que θ_k ne s'approche pas de $\pm \frac{\pi}{2}$, c-à-d que $d^{(k)}$ ne tend pas vers une direction **orthogonale au gradient**.

Plan

- 1 Conditions de Wolfe
- 2 Analyse de la méthode du gradient
 - Dans le cas d'une fonction quadratique
 - Dans le cas où f est L -smooth
 - Dans le cas (strictement) convexe
 - Dans le cas général
- 3 Méthode du gradient accéléré
- 4 Annexe : notations

Méthode du gradient/de la plus forte pente

A l'itéré k , quel choix de direction $d^{(k)}$?

- telle que $d^{(k)}$ soit une direction de descente, et
- telle que $\cos(\theta^{(k)}) > 0$?

Un choix très populaire est la **direction opposée au gradient** :

$$d^{(k)} = -\nabla f(x^{(k)}).$$

- Cette direction est une direction de descente, en effet :

$$d^{(k)T} \nabla f(x^{(k)}) = -\nabla f(x^{(k)})^T \nabla f(x^{(k)}) = -\|\nabla f(x^{(k)})\|_2^2 < 0.$$

- On a

$$\cos(\theta^{(k)}) = -\frac{\nabla f(x^{(k)})^T d^{(k)}}{\|\nabla f(x^{(k)})\| \|d^{(k)}\|} = -\frac{\nabla f(x^{(k)})^T (-\nabla f(x^{(k)}))}{\|\nabla f(x^{(k)})\| \|\nabla f(x^{(k)})\|} = \frac{\|\nabla f(x^{(k)})\|_2^2}{\|\nabla f(x^{(k)})\|_2^2} = 1.$$

Etant donné $x^{(0)}$, les itérés suivants sont obtenus par :

$$x^{(k)} = x^{(k-1)} - \alpha^{(k-1)} \nabla f(x^{(k-1)}).$$

Rappel : Méthode du gradient pour une fonction quadratique

Pour une fonction quadratique $f(x) = \frac{1}{2}x^T Qx - c^T x + p$,

- la direction est $d^{(k)} = -\nabla f(x^{(k)}) = -(Qx^{(k)} - c) = c - Qx^{(k)}$.
- le pas optimal peut être calculé exactement à chaque itération :

$$\alpha^{(k)*} = \frac{-d^{(k)T} \nabla f(x^{(k)})}{d^{(k)T} Q d^{(k)}} = \frac{\|\nabla f(x^{(k)})\|_2^2}{\nabla f(x^{(k)})^T Q \nabla f(x^{(k)})}.$$

Soit f quadratique.

Alors, pour les itérés de la méthode du gradient avec pas optimal, on a :

$$f(x^{(k+1)}) \leq f(x^{(k)}) - \frac{1}{2\lambda_{\max}(Q)} \|\nabla^2 f(x^{(k)})\|.$$

Convergence dans le cas où f est L -smooth

Soit f continument différentiable et L -smooth.

Alors, pour tout $\alpha > 0$, on a :

$$f(x^{(k+1)}) \leq f(x^{(k)}) - \alpha \left(1 - \frac{\alpha L}{2}\right) \|\nabla^2 f(x^{(k)})\| \leq f(x^{(k)}) - \frac{1}{2L} \|\nabla^2 f(x^{(k)})\|.$$

- Un pas $\alpha \in]0, \frac{2}{L}[$ implique une décroissance 'stricte'.

La condition suffisante de convergence vers un point stationnaire s'applique.
(voir cours précédent)

- Le pas $\alpha = \frac{1}{L}$ permet d'obtenir la plus grande borne sur la décroissance.
- Plusieurs stratégies pour le calcul du pas :
 - Fixe : $\alpha^{(k)} = \frac{1}{L}$ pour $k = 1, 2, \dots$
 - Recherche dimensionnelle exacte
 - Backtracking : on cherche un pas $\alpha^{(k)}$ tel que

$$f(x^{(k+1)}) \leq f(x^{(k)}) - \beta_1 \alpha^{(k)} \|\nabla^2 f(x^{(k)})\|$$

avec la règle $\alpha^{(k)} = \alpha_{\text{init}}$ et on effectue $\alpha^{(k)} = k^{(k)}/t$ tant que la condition n'est pas satisfaite.

Convergence dans le cas (strictement) convexe

Convergence sous-linéaire dans le cas convexe.

Soit f continument différentiable, L -smooth et convexe.

En effectuant les itérés

$$x^{(k)} = x^{(k-1)} - \frac{1}{L} \nabla f(x^{(k-1)}),$$

on peut montrer qu'on a :

$$f(x^{(k)}) - f^* \leq \mathcal{O}\left(\frac{1}{k}\right).$$

Convergence linéaire dans le cas strictement convexe.

Soit f continument différentiable, L -smooth et strictement convexe.

En effectuant les itérés

$$x^{(k)} = x^{(k-1)} - \frac{1}{L} \nabla f(x^{(k-1)}),$$

on peut montrer qu'on a :

$$f(x^{(k)}) - f^* \leq \mathcal{O}\left(\left(1 - \frac{\mu}{L}\right)^k\right).$$

Preuve :

$$\text{On part de } W2 : \beta_2 \underbrace{d^T \nabla f(x)}_{> 0} \leq \underbrace{d^T \nabla f(x+2d)}_{-d^T \nabla f(x)}$$

$$\begin{aligned} \hookrightarrow (\beta_2 - 1) d^T \nabla f(x) &\leq d^T (\nabla f(x+2d) - \nabla f(x)) \leq \|d\| \cdot \|\nabla f(x+2d) - \nabla f(x)\| \\ &\leq \|d\| \cdot L \cdot \|x+2d - x\| = 2L \|d\|^2 \quad \text{L-smooth} \\ &\stackrel{\text{signe}}{\nearrow} \propto L \|d\|^2 \geq (\beta_2 - 1) d^T \nabla f(x) \end{aligned}$$

$$\begin{aligned} \underbrace{d^T \nabla f(x)}_{> 0} &\propto L \|d\|^2 \geq (\beta_2 - 1) d^T \nabla f(x) \\ &\propto L \|d\|^2 d^T \nabla f(x) \leq (\beta_2 - 1) (d^T \nabla f(x))^2 \\ &\propto d^T \nabla f(x) \leq \frac{\beta_2 - 1}{L \|d\|^2} (d^T \nabla f(x))^2 \end{aligned}$$

$$\hookrightarrow \text{J'utilise } W_1 : f(x+2d) \leq f(x) + \beta_1 \propto d^T \nabla f(x) \leq f(x) + \frac{\beta_1(\beta_2 - 1)}{L \|d\|^2} \underbrace{(d^T \nabla f(x))}_{\cos^2(\theta) \cdot \|\nabla f(x)\|}$$

$$\hookrightarrow f(x+2d) \leq f(x) - \frac{\beta_1(1-\beta_2) \cdot \cos^2 \theta}{L} \cdot \|\nabla f(x)\|^2 \quad > 0$$

$\Rightarrow$ On converge vers un point stationnaire



Preuve: (avec $d = -\nabla f(x)$ et $\alpha = \frac{1}{2}$ pour f L -smooth)


$$= -2 \nabla f(x)$$

↳ itérés: $x^+ = x - \alpha \nabla f(x)$

$$\begin{aligned} \text{↳ Par Taylor: } f(x^+) &= f(x) + \nabla f(x)^T (x^+ - x) + \frac{1}{2} (x^+ - x)^T \nabla^2 f(\xi) (x^+ - x) \\ &= f(x) - \alpha \|\nabla f(x)\|^2 + \frac{\alpha^2}{2} \nabla f(x)^T \nabla^2 f(\xi) \nabla f(x) \\ &\downarrow \\ &\leq f(x) - 2\left(1 - \frac{\alpha L}{2}\right) \cdot \|\nabla f(x)\|^2 \end{aligned}$$

↳ Avec $\alpha = \frac{1}{2}$: $f(x^+) \leq f(x) - \frac{1}{2L} \|\nabla f(x)\|^2 \Rightarrow$ C.S. s'applique

$\Rightarrow$ On converge en un point stationnaire



Plan

- 1 Conditions de Wolfe
- 2 Analyse de la méthode du gradient
- 3 Méthode du gradient accéléré
 - Présentation
 - Résultats de convergence
- 4 Annexe : notations

Convergence dans le cas général

Si les hypothèses suivantes sont vérifiées :

- 1 f deux fois continûment différentiable
- 2 une recherche en ligne exacte est utilisée pour trouver le pas
- 3 les itérés convergent vers un point x^* où la hessienne $Q = \nabla^2 f(x^*) \succ 0$

alors on a :

$$f(x^{(k+1)}) - f(x^*) \leq \left(\frac{\kappa(Q) - 1}{\kappa(Q) + 1} \right)^2 \left(f(x^{(k)}) - f(x^*) \right),$$

avec $\kappa(Q) = \frac{\lambda_{\max}(Q)}{\lambda_{\min}(Q)}$.

- Recherche en ligne exacte : rarement envisageable

Gradient accéléré

Contrairement à la méthode du gradient de base (figure de gauche), on va également utiliser l'information de l'itération précédente (figure de droite) :



- 1 Choisir le paramètre $\alpha_1 \in (0, 1)$;
- 2 Choix du point initial $x^{(0)}$. On définit $y = x^{(0)}$.
- 3 $k = 1, 2, \dots$

- 1 $x^{(k)} = y - \frac{1}{L} \nabla f(y).$

- 2 $y = x^{(k)} + \beta_k (x^{(k)} - x^{(k-1)}),$

où $\beta_k = \frac{\alpha_k(1-\alpha_k)}{\alpha_k^2 + \alpha_{k+1}}$ avec $\alpha_{k+1} \geq 0$ t.q. $\alpha_{k+1}^2 = (1 - \alpha_{k+1})\alpha_k^2.$

En utilisant $\beta_k = 0$ pour tout k , on retrouve l'algorithme du gradient.

Convergence dans le cas convexe

Pour une fonction f convexe et L -smooth, on peut montrer que la méthode du gradient accéléré a une convergence sous-linéaire

$$f(x^{(k)}) - f^* \leq \mathcal{O}\left(\frac{1}{k^2}\right).$$

De plus, si f est **strictement convexe**, la méthode du gradient accéléré a une convergence linéaire

$$f(x^{(k)}) - f^* \leq \mathcal{O}\left(\left(1 - \sqrt{\frac{\mu}{L}}\right)^k\right).$$

Pour ces classes de problème, ces résultats de convergence sont optimaux pour des méthodes du premier ordre (utilisant uniquement l'information du gradient).

Plan

- 1 Conditions de Wolfe
- 2 Analyse de la méthode du gradient
- 3 Méthode du gradient accéléré
- 4 Annexe : notations

Notation

Pour une tolérance choisie ε (par ex., $\varepsilon = 10^{-6}$), on souhaite trouver $x^{(k)}$ tel que

$$f(x^{(k)}) \leq f(x^*) + \varepsilon.$$

Combien d'itérations k sont nécessaires pour atteindre cette tolérance ?

- Si le nombre d'itérations $k = \mathcal{O}\left(\frac{1}{\varepsilon^2}\right)$, cela signifie que

$$k = \text{constante} \cdot \frac{1}{\varepsilon^2}.$$

On notera alors $\varepsilon = \mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$.

- Si le nombre d'itérations $k = \mathcal{O}\left(\frac{1}{\varepsilon}\right)$, cela signifie que

$$k = \text{constante} \cdot \frac{1}{\varepsilon}.$$

On notera alors $\varepsilon = \mathcal{O}\left(\frac{1}{k}\right)$.

- Si le nombre d'itérations $k = \mathcal{O}\left(\frac{1}{\sqrt{\varepsilon}}\right)$, cela signifie que

$$k = \text{constante} \cdot \frac{1}{\sqrt{\varepsilon}}.$$

On notera alors $\varepsilon = \mathcal{O}\left(\frac{1}{k^2}\right)$.

- Si le nombre d'itérations $k = \mathcal{O}\left(\log\left(\frac{1}{\varepsilon}\right)\right)$, cela signifie que

$$k = \text{constante} \cdot \log\left(\frac{1}{\varepsilon}\right).$$

On notera alors $\varepsilon = \mathcal{O}(c^k)$.