

# MARO 036 - Optimisation Non-Linéaire

Arnaud Vandaele

Faculté Polytechnique  
Service MATHématique et Recherche Opérationnelle



Année académique 2023-2024

Séance 7 :  
Méthodes Newton/Quasi-Newton

# Séance 7 – Méthodes Newton/Quasi-Newton

## Tables des matières

1 Méthode de Newton

2 Méthode Quasi-Newton


# Plan

- 1 Méthode de Newton
- 2 Méthode Quasi-Newton

# Méthode de Newton : interprétation

En un itéré  $x^{(k)}$ , le modèle (l'approximation) quadratique est

$$m_k(x) = f(x^{(k)}) + (x - x^{(k)})^T \nabla f(x^{(k)}) + \frac{1}{2}(x - x^{(k)})^T \nabla^2 f(x^{(k)})(x - x^{(k)})$$



Le prochain itéré  $x^{(k+1)}$  est le minimum du modèle quadratique en  $x^{(k)}$ .

**Idée générale :** à chaque itéré, au lieu d'optimiser, on optimise son approximation quadratique.

# Méthode de Newton : direction de descente

Minimisation du modèle quadratique obtenu :

$$\nabla m_k(x) = 0 \Leftrightarrow \nabla f(x^{(k)}) + \nabla^2 f(x^{(k)})(x - x^{(k)}) = 0 \Leftrightarrow x - x^{(k)} = -\nabla^2 f(x^{(k)})^{-1} \nabla f(x^{(k)}).$$

Ce qui mène à

$$x^{(k+1)} = x^{(k)} - \nabla^2 f(x^{(k)})^{-1} \nabla f(x^{(k)}),$$

où on peut voir que la direction de recherche est  $d^N = -\nabla^2 f(x^{(k)})^{-1} \nabla f(x^{(k)})$ .

- Si  $\nabla^2 f(x)$  est singulière, la direction de Newton  $d^N$  n'est pas définie
- Si  $\nabla^2 f(x) \succ 0$ , alors  $d^N$  est une direction de descente, et effectuer  $x^{(k)} + d^N$  mène au **minimum global** de l'approximation quadratique
- Dans les autres cas,  $x^{(k)} + d^N$  fournit un **maximum** ou un **point selle** de l'approximation quadratique,  $d^N$  n'est **pas forcément** une direction de descente

**Lien avec la méthode de Newton-Raphson (cours Analyse Num. BAB2) :** minimiser une fonction à l'aide de la méthode de Newton présentée dans ce cours revient à résoudre le système d'équations  $\nabla f(x) = 0$ .

**Désavantage :** d n'est pas toujours une direction de descente.

**Avantage :** quand la méthode converge, elle converge avec une vitesse quadratique.

**Preuve :**

$$\begin{aligned}x^+ - x^* &= x - x^* - (\nabla^2 f(x))^{-1} \cdot \nabla f(x) \\&= x - x^* + (\nabla^2 f(x))^{-1} \cdot (-\nabla f(x) + \nabla f(x^*)) \\&= x - x^* + (\nabla^2 f(x))^{-1} \cdot (\nabla^2 f(x) \cdot (x^* - x)) \\&= (\nabla^2 f(x))^{-1} (\nabla^2 f(x) (x - x^*) + \nabla^2 f(x) \cdot (x^* - x)) \\&= (\nabla^2 f(x))^{-1} (\nabla^2 f(x) - \nabla^2 f(x^*)) \cdot (x^* - x)\end{aligned}$$

*F. avec fin*

$$\begin{aligned}\hookrightarrow \|x^+ - x^*\| &\leq \underbrace{\|\nabla^2 f^{-1}(x)\|}_{\leq \frac{1}{\mu}} \cdot \underbrace{\|\nabla^2 f(x) - \nabla^2 f(x^*)\|}_{\leq L \cdot \|x - x^*\|} \cdot \|x^* - x\| \\&\leq \frac{L}{\mu} \|x^* - x\|^2\end{aligned}$$



# Méthode de Newton - Convergence locale

## Convergence locale.

Soit  $f \in \mathcal{C}^2$  possédant un unique minimum  $x^*$  sur  $\mathbb{R}^n$ , si on suppose

- $\exists L$  tel que  $\|\nabla^2 f(x) - \nabla^2 f(y)\| \leq L \|x - y\| \quad \forall x, y$  ( $\nabla^2 f$  Lipsch. cont.)
- $\exists \mu > 0$  tel que  $\nabla^2 f(x) \succeq \mu I \quad \forall x$

alors

- les itérés  $\{x^{(k)}\}$  convergent vers  $x^*$  avec une vitesse quadratique :

$$\|x^{(k+1)} - x^*\| \leq \frac{L}{\mu} \|x^{(k)} - x^*\|^2.$$

De plus, si  $\|x^{(0)} - x^*\| \leq \frac{\mu}{L}$ , alors

$$\|x^{(k)} - x^*\| \leq \frac{\mu}{L} \left(\frac{1}{2}\right)^{2^k}.$$

- la norme du gradient  $\|\nabla f(x^{(k)})\|$  tend quadratiquement vers 0



# Méthode de Newton - Convergence globale

Application de la condition de Zoutendijk

## Convergence globale.

- $f$  est bornée inférieurement, continûment différentiable et de gradient  $\nabla f$  Lipschitz continu
- $d^{(k)} = -\nabla^2 f(x^{(k)})^{-1} \nabla f(x^{(k)})$  avec  $\nabla^2 f(x^{(k)}) \succ 0 \forall k$   
(les directions  $d^{(k)}$  sont des directions de descente)
- les pas  $\alpha^{(k)}$  satisfont aux conditions de Wolfe
- $\|\nabla^2 f(x^{(k)})\| \|\nabla^2 f(x^{(k)})^{-1}\| \leq M$  pour tout  $k$   
(l'angle  $\theta_k$  vérifie la relation  $\cos \theta_k \geq \frac{1}{M}$ )

alors

- la méthode de Newton **converge globalement**

Résultat **incompatible** avec la convergence locale **quadratique**  
(qui nécessite des longueurs de pas unitaires  $\alpha^{(k)} = 1$ )

## La direction de Newton est (très) coûteuse

$$d^N = -\nabla^2 f(x)^{-1} \nabla f(x)$$

- Pour calculer cette direction, il faut d'abord calculer  $\nabla^2 f(x^{(k)})$ . Cela peut être **coûteux** en mémoire et en temps de calcul (la matrice comporte potentiellement  $\frac{1}{2}n(n+1)$  éléments), et les multiples dérivations nécessaires sont sujettes à des **erreurs** de calcul.
- Une fois  $\nabla^2 f(x^{(k)})$  calculée, la direction  $d^{(k)} = -\nabla^2 f(x^{(k)})^{-1} \nabla f(x^{(k)})$  s'obtient en résolvant le **syst. lin.** :

$$\nabla^2 f(x^{(k)}) d^{(k)} = -\nabla f(x^{(k)})$$

(et **pas en inversant** la matrice hessienne  $\nabla^2 f(x^{(k)})$ )

Pour une matrice hessienne typique :  $\mathcal{O}(n^3)$  opérations

Les méthodes de **quasi-Newton** visent à pallier tous ces inconvénients

# Plan

## 1 Méthode de Newton

## 2 Méthode Quasi-Newton

- Description
- Mise à jour SR1
- Mise à jour BFGS

## Idee générale : on approxime $\nabla^2 f(x^{(k)})$

Dans le modèle quadratique  $m_k(x)$ , la matrice hessienne  $\nabla^2 f(x^{(k)})$  est remplacée par une approximation  $B_k$  :

$$m_k(x) = f(x^{(k)}) + (x - x^{(k)})^T \nabla f(x^{(k)}) + \frac{1}{2} (x - x^{(k)})^T B_k (x - x^{(k)})$$

Et la minimisation de ce modèle mène à :

$$x^{(k+1)} = x^{(k)} - B_k^{-1} \nabla f(x^{(k)}),$$

la direction de recherche est donc  $-B_k^{-1} \nabla f(x^{(k)})$ .

- La direction de quasi-Newton est définie par

$$d^{QN} = -B_k^{-1} \nabla f(x^{(k)})$$

- Idéalement,  $B_k$  doit être facile à calculer et à stocker
- $B_k$  devrait être proche de  $\nabla^2 f(x^{(k)})$  pour conserver les bonnes propriétés du pas de Newton (convergence quadratique)
- $B_k$  sera toujours choisie symétrique (car  $\nabla^2 f(x^{(k)})$  l'est)
- Si  $B_k$  est définie positive,  $d^{QN}$  est une direction de descente
- Lorsque,  $\forall k$ , on a  $B_k = I$ , on retrouve la méthode du gradient

# Algorithme Quasi-Newton

C'est également une méthode de recherche en ligne

- 1 Soit un point de départ  $x^{(0)} \in \mathbb{R}^n$  et un indice  $k := 0$   
Soit  $B_0$  une approximation initiale de la hessienne :  $B_0 \approx \nabla^2 f(x^{(0)})$
- 2 Tant qu'on n'est pas suffisamment proche d'un minimum
  - 1 Calculer la  $d^{(k)} = -B_k^{-1} \nabla f(x^{(k)})$
  - 2 Choisir une **longueur de pas**  $\alpha^{(k)}$  qui **minimise** (éventuellement approximativement)

$$\min_{\alpha > 0} g(\alpha) = f(x^{(k)} + \alpha d^{(k)})$$

(par exemple en respectant les conditions de Wolfe)

- 3 Calculer l'**itéré** suivant  $x^{(k+1)} := x^{(k)} + \alpha_k d^{(k)}$
- 4 Calculer une nouvelle **approximation de la hessienne**  $B_{k+1}$   
(en essayant de respecter  $B_{k+1} \approx \nabla^2 f(x^{(k+1)})$ )
- 5 Et incrémenter  $k := k + 1$

Avant de décrire plus précisément le calcul de  $B_{k+1}$ , on va analyser les propriétés générales de **convergence** de cette méthode.

# Quasi-Newton - Convergence globale

Exactement comme pour les autres méthodes, on applique Zoutendijk

## Convergence globale.

- $f$  est bornée inférieurement, continûment différentiable et de gradient  $\nabla f$  Lipschitz continu
- $d^{(k)} = -B_k^{-1} \nabla f(x^{(k)})$  avec  $B_k \succ 0 \forall k$   
(les directions  $d^{(k)}$  sont des directions de descente)
- les pas  $\alpha^{(k)}$  satisfont aux conditions de Wolfe
- $\|B_k\| \|B_k^{-1}\| \leq M$  pour tout  $k$   
(l'angle  $\theta_k$  vérifie la relation  $\cos \theta_k \geq \frac{1}{M}$ )

alors

- la méthode de Quasi-Newton **converge globalement**

(on retrouve bien la direction de Newton lorsque  $B_k = \nabla^2 f(x^{(k)})$ .)

# Quasi-Newton - Convergence locale

Lorsqu'une méthode QN **converge**, il est possible de caractériser sa vitesse.  
On suppose

- 1  $\nabla^3 f(x^{(k)})$  est continu
- 2 le pas  $\alpha^{(k)}$  satisfait aux conditions de Wolfe avec  $\beta_1 \leq \frac{1}{2}$
- 3 la suite  $\{x^{(k)}\}$  **converge** vers un point  $x^*$  tel que

$$\nabla f(x^*) = 0 \text{ et } \nabla^2 f(x^*) \succ 0 \quad (\text{minimum strict})$$

- 4 les approximations  $B_k$  choisies satisfont

$$\lim_{k \rightarrow \infty} \frac{\|(B_k - \nabla^2 f(x^*))d^{(k)}\|}{\|d^{(k)}\|} = 0$$

Si ces **4 conditions** sont satisfaites, alors

- il existe un certain indice  $k_0$  tel que la longueur de pas  $\alpha^{(k)} = 1$  est admissible pour tout  $k \geq k_0$ ,
- et si on a effectivement choisi  $\alpha^{(k)} = 1$  pour tout  $k \geq k_0$ , la suite  $\{x^{(k)}\}$  converge **superlinéairement**.

On a donc montré que **si il y a convergence**, elle est **superlinéaire**, à condition d'avoir pris à partir d'un certain moment des pas de longueur **unitaire**

## Comment choisir l'approximation $B_{k+1}$ ?

Dans le modèle quadratique, on remplace la matrice Hessienne  $\nabla^2 f(x^{(k+1)})$  par une approximation  $B_{k+1}$  (également symétrique):

$$m_{k+1}(x) = f(x^{(k+1)}) + (x - x^{(k+1)})^T \nabla f(x^{(k+1)}) + \frac{1}{2}(x - x^{(k+1)})^T B_{k+1}(x - x^{(k+1)})$$

Basée sur le développement de Taylor, les conditions à respecter sont :

- 1 Etre égal au gradient de la fonction en  $x^{(k)}$  :  $\nabla m_{k+1}(x^{(k)}) = \nabla f(x^{(k)})$
- 2 Etre égal au gradient de la fonction en  $x^{(k+1)}$  :  $\nabla m_{k+1}(x^{(k+1)}) = \nabla f(x^{(k+1)})$

Ces conditions mènent à :

$$B_{k+1}(x^{(k+1)} - x^{(k)}) = \nabla f(x^{(k+1)}) - \nabla f(x^{(k)})$$

En posant

- $s_k = x^{(k+1)} - x^{(k)} = \alpha^{(k)} d^{(k)}$  (différence entre itérés = pas effectué),
- $y_k = \nabla f(x^{(k+1)}) - \nabla f(x^{(k)})$  (différence entre gradients)

nous avons la condition appelée **condition de la sécante** :

$$B_{k+1}s_k = y_k.$$



## Condition supplémentaire sur $B_k$ : être de faible rang

La condition de la sécante  $B_{k+1}s_k = y_k$ , même combinée à la condition de symétrie n'est pas suffisante pour déterminer  $B_{k+1}$ . De plus, comme  $B_{k+1}$  doit être facile à calculer et à stocker, on va imposer la règle suivante :

$B_{k+1}$  est obtenue à **partir de**  $B_k$  en y ajoutant une perturbation de **rang faible**.

Avantages :

- Une matrice symétrique de rang faible a beaucoup moins de degrés de liberté qu'une matrice quelconque.
- Cela implique moins de degrés de liberté sur le choix de  $B_{k+1}$ .
- Stockage aisé (uniquement la matrice initiale et les perturbations successives).

### Différentes techniques

- Mise à jour de rang 1 (SR1)
- Mise à jour de rang 2 (BFGS)

## Mise à jour symétrique de rang 1 (SR1)

- On choisit une perturbation **de rang 1**
- Elle doit être symétrique pour préserver la symétrie de  $B_{k+1}$
- Une telle perturbation  $B_{k+1} - B_k$  de rang 1 s'écrit  $\pm(xx^T)$  où  $x$  est un vecteur  $\rightarrow$  on dispose de  $n$  degrés de liberté
- La condition de la sécante impose de son côté  $n$  égalités
- Par conséquent, il n'est pas surprenant qu'il n'existe qu'**une seule** perturbation **symétrique de rang 1** vérifiant la condition de la sécante, fournie par la formule (SR1)

$$B_{k+1} = B_k + \frac{(y_k - B_k s_k)(y_k - B_k s_k)^T}{(y_k - B_k s_k)^T s_k}$$

(le produit scalaire au dénominateur étant un simple facteur multiplicatif)

- Toutefois, si le dénominateur s'annule, alors il n'**existe pas** de perturbation symétrique de rang 1 vérifiant la condition de la sécante

# Calcul du pas sans résolution de système linéaire

En fait, on ne fait pas vraiment comme décrit dans le slide précédent, mais presque...

Plutôt que de calculer la suite d'approximations de la hessienne  $B_1$ ,  $B_2$ , etc. à l'aide de l'approximation initiale  $B_0$  et de la formule (SR1)

$$B_{k+1} = B_k + \frac{(y_k - B_k s_k)(y_k - B_k s_k)^T}{(y_k - B_k s_k)^T s_k}$$

et, à chaque itération, calculer la direction selon

$$d_k = -B_k^{-1} \nabla f(x^{(k)}),$$

on va plutôt approximer l'**inverse** de la hessienne :  $H_k \approx \nabla^2 f(x^{(k)})^{-1}$  qu'on mettra également à jour à l'aide d'approximations de rang faible. On peut démontrer que la formule (SR1) conduit **aux mêmes itérés** que

$$H_0 = B_0^{-1} \text{ puis } H_{k+1} = H_k + \frac{(s_k - H_k y_k)(s_k - H_k y_k)^T}{(s_k - H_k y_k)^T y_k}.$$

La direction de quasi-Newton se calcule alors très simplement :

$$d^{(k)} = -H_k \nabla f(x^{(k)}) \quad (\text{seulement } \mathcal{O}(n^2) \text{ opérations}).$$

# Inconvénients de SR1

$$H_{k+1} = H_k + \frac{(s_k - H_k y_k)(s_k - H_k y_k)^T}{(s_k - H_k y_k)^T y_k}$$

- Si le dénominateur s'annule, il n'**existe pas** de perturbation symétrique de rang 1 vérifiant la condition de la sécante
- Rien ne garantit que  $H_{k+1}$  (ou  $B_{k+1}$ ) sera **définie positive** (propriété pourtant nécessaire pour garantir une direction de **descente** et, à partir de là, la convergence **globale**)
- En fait, on ne dispose ni de preuve de convergence globale, ni de preuve de convergence **locale** superlinéaire pour SR1 ; en particulier on ne peut démontrer que

$$\lim_{k \rightarrow \infty} \frac{\| (H_k^{-1} - \nabla^2 f(x^*)) d^{(k)} \|}{\| d^{(k)} \|} = 0 \quad ??$$

## Mise à jour BFGS (de rang 2)

La mise à jour **BFGS** (Broyden-Fletcher-Goldfarb-Shanno) va pallier tous les inconvénients de SR1 : si on pose  $\rho_k = (y_k^T s_k)^{-1}$ , elle est définie par la formule

$$H_{k+1} = (I - \rho_k s_k y_k^T) H_k (I - \rho_k y_k s_k^T) + \rho_k s_k s_k^T$$

Il s'agit d'une mise à jour de **rang 2**, qui correspond également à

$$B_{k+1} = B_k + \frac{y_k y_k^T}{y_k^T s_k} - \frac{B_k s_k s_k^T B_k}{s_k^T B_k s_k}$$

(formule équivalente pour l'approximation de la hessienne  $B_k$  au lieu de l'inverse  $H_k$ )

# Origine de BFGS

On peut démontrer que la mise à jour BFGS

$$H_{k+1} = (I - \rho_k s_k y_k^T) H_k (I - \rho_k y_k s_k^T) + \rho_k s_k s_k^T$$

est la solution du problème d'optimisation

$$\min_H \|H - H_k\|_W \text{ tel que } H = H^T \text{ et } Hy_k = s_k$$

où la norme utilisée pour mesure l'écart avec  $H_k$  est définie par

$$\|A\|_W = \|W^{\frac{1}{2}} A W^{\frac{1}{2}}\|_F$$

$\|\cdot\|_F$  est la norme de Frobenius d'une matrice et  $W$  est n'importe quelle matrice vérifiant  $Wy_k = s_k$

# Propriétés de BFGS

Si une méthode de quasi-Newton BFGS est utilisée avec une longueur de pas satisfaisant aux conditions de **Wolfe** (obtenue en commençant par tester la longueur unitaire)

- $H_k \succ 0 \Rightarrow H_{k+1} \succ 0$ , donc on a :  $H_0 \succ 0 \Rightarrow H_k \succ 0$  pour tout  $k$
- Sous les conditions supplémentaires (pas tellement restrictives)

$f \in \mathcal{C}^2$ ,  $\Omega = \{x \in \mathbb{R}^n \mid f(x) \leq f(x^{(0)})\}$  est un ensemble convexe

et il existe des constantes  $\mu$  et  $L$  telles que

$$\mu I \preceq \nabla^2 f(x) \preceq L I \text{ pour tout } x \in \Omega$$

la méthode **converge globalement** quelle que soit  $H_0 \succ 0$

- De plus, la convergence est **superlinéaire** si la méthode converge vers un point  $x^*$  où la hessienne est Lipschitz continue, c-à-d  $\exists L > 0$  :

$$\|\nabla^2 f(x) - \nabla^2 f(x^*)\| \leq L \|x - x^*\| \text{ pour tout } x \text{ dans un voisinage de } x^*$$

# Algorithme Quasi-Newton

**Entrées :** Point de départ  $x^{(0)}$ , matrice  $H_0$  initiale.

- **Etape 1 :** Calculer la direction de Quasi-Newton

$$d^{(k)} = -H_k \nabla f(x^{(k)})$$

- **Etape 2 :** Recherche linéaire satisfaisant les cond. de Wolfe afin de déterminer  $\alpha^{(k)}$ .
- **Etape 3 :**  $x^{(k+1)} = x^{(k)} + \alpha^{(k)} d^{(k)}$
- **Etape 4 :** A l'aide de  $s_k = x^{(k+1)} - x^{(k)}$  et  $y_k = \nabla f(x^{(k+1)}) - \nabla f(x^{(k)})$ , calculer  $H_{k+1}$  à l'aide la mise à jour BFGS.

SI (Critère d'arrêt vérifié)  $\rightarrow$  STOP

SINON  $\rightarrow$  Retour à l'étape 1.

## Initialisation de $H$ ?

Il n'existe pas de formule magique efficace pour tous les problèmes.

- Approximation de la matrice hessienne par différences finies en  $x_0$ .
- Matrice identité.
- Multiple de la matrice identité.
- $H_0 = I$  pour le calcul de  $x_1$  et  $H_0 = \frac{y_k^T s_k}{y_k^T y_k} I$  pour le calcul de  $H_1$ .