

Rappels:

1) Vecteurs gradients et matrice Hessienne pour $f: \mathbb{R}^n \rightarrow \mathbb{R}$

Gradient

$$\nabla f(x) = \begin{pmatrix} \frac{\partial f}{\partial x_1}(x) \\ \vdots \\ \frac{\partial f}{\partial x_n}(x) \end{pmatrix}$$

Ex. ①: $\nabla f_1(x) = \begin{pmatrix} x_1 \\ 4x_2 \end{pmatrix} \longrightarrow \nabla^2 f_1(x) = \begin{pmatrix} 1 & 0 \\ 0 & 4 \end{pmatrix}$

$$\nabla f_2(x) = \begin{pmatrix} e^{x_1} + 2x_1x_3 - x_2x_3 \\ -x_1x_3 \\ x_1^2 - x_1x_2 \end{pmatrix} \longrightarrow \nabla^2 f_2(x) = \begin{pmatrix} e^{x_1} + 2x_3 & -x_3 & 2x_1 - x_2 \\ -x_3 & 0 & -x_1 \\ 2x_1x_2 & -x_1 & 0 \end{pmatrix}$$

!!! VECTEUR !!! gradient

Matrice Hessienne

$$\nabla^2 f(x) = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2}(x) & \dots & \frac{\partial^2 f}{\partial x_1 \partial x_n}(x) \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1}(x) & \dots & \frac{\partial^2 f}{\partial x_n^2}(x) \end{pmatrix}$$

N.B.: la matrice est symétrique

Les $\neq$ produits:

• 2 vecteurs $x = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}$ $y = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}$
 $\rightarrow x^T y = (x_1 \dots x_n) \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix} = x_1 y_1 + \dots + x_n y_n \Rightarrow$ un scalaire

• une matrice $A = \begin{pmatrix} a_{11} & \dots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \dots & a_{nn} \end{pmatrix}$
 $A \cdot x = \begin{pmatrix} \\ \vdots \\ \end{pmatrix}_{n \times 1} \begin{pmatrix} \\ \vdots \\ \end{pmatrix}_{n \times 1} = \begin{pmatrix} \\ \vdots \\ \end{pmatrix}_{n \times 1} \Rightarrow$ un vecteur

• $x^T A x$ $\Rightarrow$ un scalaire
 On aura souvent $A =$ mat. Hessienne et $x^T, x =$ vecteur / direction.

2) Valeurs et vecteurs propres

$$A x = \lambda x$$

$x =$ vect. propre


$\lambda =$ valeur propre

Vérif des dimensions: $A x =$ vecteur et $\lambda x =$ vecteur $\Rightarrow$ ok ✓
 $\mathbb{R} \rightarrow \mathbb{R}^n$, différents cas pour n .

• $n = 1$

Pour la forme quadratique $a x^2$
 $\mathbb{R} \rightarrow \mathbb{R} \Rightarrow$ parabole

si $a > 0$
 si $a < 0$



$a x^2 \geq 0 \quad \forall x$
 $a x^2 \leq 0 \quad \forall x$

• $n \geq 2$

Pour la forme quadratique $x^T A x \Rightarrow$

$\hookrightarrow n = 2$: $x^T A x = (x_1 \ x_2) \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = a_{11} x_1^2 + (a_{12} + a_{21}) x_1 x_2 + a_{22} x_2^2$

Une fct $f: \mathbb{R}^n \rightarrow \mathbb{R}$ est dite quadratique si elle peut s'écrire sous la forme:

$$f(x) = \frac{1}{2} x^T A x - b^T x + c \quad \text{si } A \in \mathbb{R}^{n \times n} \text{ et symétrique, } b \in \mathbb{R}^n \text{ et } c \in \mathbb{R}.$$

THÉORÈME SPECTRAL

Pour A de taille $n \times n$ symétrique, A possède n valeurs propres réelles $\lambda_1, \dots, \lambda_n$

A possède n vecteurs propres orthogonaux $v_1, \dots, v_n$ (ils forment une base dans $\mathbb{R}^n$)

Donc, par le théorème spectral, pour tout $x \in \mathbb{R}^n$, on a: $x = \alpha_1 v_1 + \dots + \alpha_n v_n$

- si $x = v_i$, $x^T A x = v_i^T A v_i = v_i^T (\lambda_i v_i) = \lambda_i v_i^T v_i = \lambda_i \cdot 1 = \lambda_i$


$\Rightarrow$ " $x^T A x$ " lorsque x est vecteur propre dans la valeur propre correspondante

- si $x = \alpha_1 v_1 + \dots + \alpha_n v_n$, $x^T A x = (\alpha_1 v_1 + \dots + \alpha_n v_n)^T A (\alpha_1 v_1 + \dots + \alpha_n v_n)$

$$= \alpha_1^2 v_1^T A v_1 + \alpha_2^2 v_2^T A v_2 + \dots + \alpha_n^2 v_n^T A v_n$$
 Par le théorème spectral, les v_i sont orthogonaux.

$$= \alpha_1^2 \lambda_1 + \alpha_2^2 \lambda_2 + \dots + \alpha_n^2 \lambda_n$$
 Résultat précédent

$$\|x\|^2 \lambda_{\min} \leq x^T A x \leq \|x\|^2 \lambda_{\max}$$



D'où l'équivalence :

$$A \succ 0 \Leftrightarrow \lambda_i > 0 \quad \forall i \Leftrightarrow x^T A x > 0 \quad \forall x$$

Imaginons une matrice où toutes les valeurs propres sont > 0 , sauf une qui est $\lambda_{\max} < 0$.

$$\text{Avec } x = v_{\max}, \quad x^T A x = \lambda_{\max} < 0.$$

Si les valeurs propres de A sont $\lambda_1, \dots, \lambda_n$, quelles sont les valeurs propres de $A - \mu I$? $\Rightarrow \lambda_1 - \mu, \lambda_2 - \mu, \dots, \lambda_n - \mu$

$$A \succ 0 \Leftrightarrow \lambda_i > 0 \quad \forall i, \quad A \text{ définie positive.}$$

$$A \succeq 0 \Leftrightarrow \lambda_i \geq 0 \quad \forall i, \quad A \text{ semi-définie positive.}$$

$$A \succeq \mu I \Leftrightarrow A - \mu I \succeq 0 \Leftrightarrow \lambda_i - \mu \geq 0 \Leftrightarrow \lambda_i \geq \mu.$$

$$M I \succeq A \succeq \mu I$$

$$\Leftrightarrow \mu \leq \lambda_i \leq M \quad \xrightarrow{\quad} \quad \mu, M = \text{bornes}$$

3) Fonctions quadratiques

$$f(x) = \frac{1}{2} x^T A x - b^T x + c$$

$$\nabla f(x) = \frac{A+A^T}{2} x - b \quad \text{et} \quad \text{qd } A \text{ est symétrique} \quad \nabla f(x) = Ax - b$$

$$\nabla^2 f(x) = \frac{A+A^T}{2} \quad \nabla^2 f(x) = A$$

$$f(x_1, x_2) = 3x_1^2 + 4x_1x_2 + 6x_2^2 - 3x_1 + 5x_2$$

$$= \frac{1}{2} x^T A x - b^T x + c$$

$$\text{Donc, } \nabla f(x) = \begin{pmatrix} 6 & 4 \\ 4 & 12 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} - \begin{pmatrix} 3 \\ -5 \end{pmatrix}$$

$$\nabla^2 f(x) = \begin{pmatrix} 6 & 4 \\ 4 & 12 \end{pmatrix}$$

4) Taylor

$$\text{de manière générale : } f(x) = P_k(x) + R(x)$$

$$(a) \text{ Pour } n=1: \quad f(x) = f(a) + f'(a)(x-a) + f''(a) \frac{(x-a)^2}{2} + \dots + \frac{f^{(k)}(a)}{k!} (x-a)^k + \frac{f^{(k+1)}(\xi)}{(k+1)!} (x-a)^{k+1} \quad \text{avec } \xi \in [a, x]$$

Exemple :

$$f(x) = e^x \quad \Rightarrow \quad e^x = 1 + x + \frac{x^2}{2} + \frac{x^3}{6} + \underbrace{\frac{e^\xi}{24} x^4}_{o(x^3)} \quad \text{avec } \xi \in [a, x]$$

Que peut-on dire sur le terme d'erreur ?

$$\forall \varepsilon > 0, \exists \delta > 0 : \forall x \in E, \quad x \in V_\delta^*(a) \Rightarrow |f(x)| \leq \varepsilon |g(x)|$$

$$\Rightarrow \left| \frac{f(x)}{g(x)} - 0 \right| \leq \varepsilon$$

$\Leftrightarrow$

$$\lim_{x \rightarrow a} \left| \frac{f(x)}{g(x)} \right| = 0$$

$$f(x) = o(g(x)) \text{ ou voisinage de } a$$

$\hookrightarrow f(x)$ est négligeable par rapport à $g(x)$ ou voisinage de a

Pour Taylor, on aurait imposé :

$$\lim_{x \rightarrow a} \frac{f(x) - P_k(x)}{(x-a)^k} = 0 \quad \text{"} f(x) - P_k(x) \text{ doit être négligeable par rapport à } (x-a)^k \text{"}$$

$\hookrightarrow$ Lorsque x s'approche de a , le terme $R(x)$ devient négligeable par rapport à $(x-a)^k$, on note alors $R(x) = o((x-a)^k)$

Si on reprend notre exemple


$$e^x - \left(1 + x + \frac{x^2}{2} + \frac{x^3}{6} \right) = \text{erreur d'approximation qui est négligeable} \quad \text{q. à } x^3.$$

$$= R(x) = \frac{f^{(k+1)}(\xi)}{(k+1)!} (x-a)^{k+1} = o((x-a)^k)$$

Quelques exemples

1) On a $\{n^2 = o(n) \rightarrow n^2, \text{ autour de } n=0, \text{ est négligeable par rapport à } n\}$

Donc, il est toujours possible de trouver un voisinage autour de $a=0$, tel que $\begin{cases} |n^2| < \varepsilon |n| & \forall \varepsilon > 0 \\ |f(n)| < \varepsilon |n^2| \end{cases}$



$$-\varepsilon |n| \leq o(n) \leq \varepsilon |n|$$

(b) Pour $k \geq 2$

$$k=1: f(n) = f(a) + \nabla f(a)^T (n-a) + o(\|n-a\|)$$

$$k=2: f(n) = f(a) + \nabla f(a)^T (n-a) + \frac{1}{2} (n-a)^T \nabla^2 f(a) (n-a) + o(\|n-a\|^2)$$

Le pt a sera un déplacement par rapport à a :

$$n = a + \underbrace{\alpha}_{\in \mathbb{R}^n} \underbrace{d}_{\in \mathbb{R}^n}$$

$$\|n-a\| = \|\alpha d\| = |\alpha| \cdot \|d\| = |\alpha|$$

$\rightarrow a$ c'est une position et d est une direction.

En remplaçant $n = a + \alpha d$ on obtient

$$k=1: f(a+\alpha d) = f(a) + \alpha \nabla f(a)^T d + o(|\alpha|)$$

$$k=2: f(a+\alpha d) = f(a) + \alpha \nabla f(a)^T d + \frac{\alpha^2}{2} d^T \nabla^2 f(a) d + o(\alpha^2)$$

pour des petites variat° de n autour de a , on cherche la variat° dans une direct° particulière d .
Donc, on explore autour du pt a .

Exemple

$$\text{Soit } f(x_1, x_2) = ((x_1 + x_2)^2 - 1)^2$$

$$a = \left(\frac{1}{4}, \frac{1}{4}\right), \quad d = (1, 1), \quad k=2$$

$$\nabla f(a) = \begin{pmatrix} 2 \cdot ((x_1 + x_2)^2 - 1) & 2 \cdot (x_1 + x_2) \\ 2 \cdot ((x_1 + x_2)^2 - 1) & 2 \cdot (x_1 + x_2) \end{pmatrix}$$

$$\nabla^2 f(a) = \begin{pmatrix} 4 \cdot (x_1 + x_2) & 2 \cdot (x_1 + x_2)^2 - 4 \\ 2 \cdot (x_1 + x_2)^2 - 4 & 4 \cdot (x_1 + x_2) \end{pmatrix}$$

$$P_2(n) = f(a) + \alpha \nabla f(a)^T d + \frac{\alpha^2}{2} d^T \nabla^2 f(a) d$$


$$= \left[\left(\frac{1}{4} + \frac{1}{4} \right)^2 - 1 \right]^2 + \alpha \cdot \begin{pmatrix} -\frac{3}{2} & -\frac{3}{2} \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} + \frac{\alpha^2}{2} \begin{pmatrix} 1 & 1 \end{pmatrix} \begin{pmatrix} -1 & -1 \\ -1 & -1 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

$$= \frac{9}{16} + \alpha \cdot (-3) + \frac{\alpha^2}{2} \cdot (-4)$$

$$= \frac{9}{16} - 3\alpha - 2\alpha^2$$

$$f(a+\alpha d) = \frac{9}{16} - 3\alpha - 2\alpha^2 + o(\alpha^2)$$


On revient à un pb à 1 variable: on a une position, a se déplace et on cherche la meilleure parabole qui approxime au mieux le pt a dans la direction du déplacement.



5) "Il n'y a pas d'approx"

Rappel d'une fonction continue au sens de Lipschitz:

Continuité au sens de Lipschitz



Si je fais bouger mon petit papillon, ma fonction se trouve toujours dans la partie colorée.

Qu

On peut aussi dire que sa dérivée est bornée par L .

$\Rightarrow$ une fonction Lipschitz-continue c'est une fonction "gentille", elle ne fluctue pas trop.

Une fonction f est Lipschitz continue s'il existe une constante $L > 0$ telle que $\forall x_1, x_2$, on a

$$|f(x_1) - f(x_2)| \leq L |x_1 - x_2|.$$

Une fonction dont la dérivée est Lipschitz continue avec une constante L est appelée une fonction L -smooth.

Minimas globaux, locaux, et stricts pour $f : \mathbb{R}^n \rightarrow \mathbb{R}$

$$\min_x f(x) \text{ tel que } x \in X$$

- $x^* \in X$ est un minimum **global** ssi

$$f(x^*) \leq f(x) \quad \forall x \in X$$

- $x^* \in X$ est un minimum **local** ssi

$$\exists \delta > 0 : \forall x \in X, \|x - x^*\| \leq \delta \Rightarrow f(x^*) \leq f(x)$$

Il existe un certain voisinage S dans lequel x^* se trouve. x^* est le min ($f(x^*) \leq f(x)$) dans ce voisinage.
 $f(x^*) \leq f(x) \quad \forall x \in S$

- $x^* \in X$ est un **minimum local strict** ssi

$$\exists \delta > 0 : \forall x \in X, 0 < \|x - x^*\| \leq \delta \Rightarrow f(x^*) < f(x)$$

Trouver une méthode spécifique afin de trouver un minimum global est sans espoir...

Afin de montrer que la recherche du minimum global pour **n'importe quel problème** est compliquée, nous allons **calculer une borne inférieure** sur le nombre de points à évaluer.

↳ But = savoir combien de points il est nécessaire d'évaluer

Cet exemple est illustratif, nous pouvons donc nous fixer quelques hypothèses : pour obtenir une erreur ϵ acceptable.

- La fonction $f : \mathbb{R}^n \rightarrow \mathbb{R}$ est Lipschitz continue avec une constante L .
- La borne inférieure calculée sera pour des **méthodes d'ordre 0** (aucune information sur les dérivées n'est utilisée).
- L'espace de travail est la boule $([0, 1])^n$.

La fonction utilisée est la **pire** possible :

pour n'importe quel point x évalué, la réponse est la même : $f(x) = 0$.


0 est juste un exemple, c'est le fait que la fct soit constante qui fait que c'est la pire cas.

Afin de n'avoir qu'une erreur ϵ par rapport au minimum global ($f(x) - f^* \leq \epsilon$), quel doit être le nombre p de points évalués ?

NB : En effet une fonction est, chaque pt évalué donnera la m même valeur, ce qui empêche de progresser vers un minimum identifiable.

Faisons l'exemple avec $n=1$

Exemple pour $n = 1$:



$$\text{Comment trouver } \frac{\epsilon}{L} : l = \frac{\Delta y}{\Delta x} = \frac{\epsilon}{\Delta x} \Leftrightarrow \Delta x = \frac{\epsilon}{L}$$

Pour $p+1$ points on a des intervalles de longueurs $\frac{1}{p}$.

$$\text{et } \frac{1}{p} \leq 2 \cdot \frac{\epsilon}{L} \Leftrightarrow p \geq \frac{L}{2\epsilon} \text{ pour } n=1$$

En généralisant pour n dimensions : $p \geq \left(\frac{L}{2\epsilon}\right)^n$

- C'est sans espoir ... de découvrir une méthode permettant de trouver le minimum global de tous les problèmes !
- Un algorithme universel n'existe pas. Il est cependant possible de résoudre efficacement toute une série de problèmes à l'aide de méthodes dédiées.