

Séance 6

Cond. suff. de convergence.
Si les itérés suivent :
$$f(n^{(k+1)}) \leq f(n^{(k)}) - \mu \|\nabla f(n^{(k)})\|^2$$

 $\Rightarrow$ On converge vers un pt stationnaire

Preuve

$$n^{(k+1)} = n^{(k)} + \underbrace{\alpha^{(k)}}_{\text{pas}} d^{(k)} \quad \text{direct}^{\circ}$$

Séance 5, on a fini par :

Pour f quadratique
* α : direct
* d : -gradient
 $\Rightarrow$ C.S. (Preuve)

Pour f quadratique
* α : $\frac{1}{L}$ (avec $L = \lambda_{\max}(A)$)
* d : -gradient
 $\Rightarrow$ C.S. (Preuve)

Séance 6 - Structure

PREUVES

$\left\{ \begin{array}{l} * f \text{ quelconque } L\text{-smooth} \\ * \alpha = ? \text{ condit}^{\circ} \text{ de Wolfe} \\ * d : |\cos(\theta)| \geq \delta > 0 \text{ avec } \theta \text{ d'entre } d \text{ et } -\text{gradient} \end{array} \right\} \Rightarrow$ C.S. (Preuve (1))

$\left\{ \begin{array}{l} * f \text{ quelconque } L\text{-smooth} \\ * \alpha = \frac{1}{L} \\ * d = -\text{gradient} \end{array} \right\} \Rightarrow$ C.S. (Preuve (2))
 $\rightarrow + f$ convexe $\Rightarrow$ vitesse sous linéaire (Preuve (3))
 $\rightarrow + f$ strict. convexe $\Rightarrow$ vitesse linéaire (Preuve (4))

+ GRADIENT ACCÉLÉRER (pas de preuves trop technique)

L -smooth ? $\neq$ Lipschitz continue : $|f(n_2) - f(n_1)| \leq L \|n_2 - n_1\|$ ou $\frac{|f(n_2) - f(n_1)|}{\|n_2 - n_1\|} \leq L$ "dérivée première bornée par L"
 $\rightarrow$ C'est la dérivée première qui est Lipschitz continue.
 $\Rightarrow |f'(n_2) - f'(n_1)| \leq L \|n_2 - n_1\| \rightarrow \frac{|f'(n_2) - f'(n_1)|}{\|n_2 - n_1\|} \leq L$ "dérivée seconde bornée par L"


Pour $f : \mathbb{R}^n \rightarrow \mathbb{R}$

$$\lambda_{\max}(\nabla^2 f(n)) \leq L$$

$$\nabla^2 f(n) \leq L \cdot I$$

$$d^T \nabla^2 f(n) d \leq L \|d\|^2 \quad (*)$$

$\rightarrow$ Preuve (2)




$\rightarrow$ On peut bien sûr par en-dessus et par en-dessous une fct quelconque par des fcts quadratiques.

Et la convexité de f ?

$$\nabla^2 f(n) \geq \mu I \text{ avec } \mu > 0$$


$$\lambda_{\min}(\nabla^2 f(n)) \geq \mu > 0$$

Strictement convexe : $\mu > 0$



$$\mu \cdot n = \|n\| \cdot \|n\| \cdot \|\cos \theta\|$$

produit scalaire



direct $^{\circ}$ du descente : $d^T \nabla f(n^{(k)}) < 0$


$\theta = \angle$ entre d et $-\nabla f(n^{(k)})$

$$\cos(\theta) = \frac{-\nabla f(n^{(k)})^T d}{\|\nabla f(n^{(k)})\| \cdot \|d\|}$$

$\rightarrow$ Conditions de Wolfe (Armijo - Wolfe)

Quand on a une fonction f qui n'est pas quadratique, et une direct $^{\circ}$ de recherche d , comment calculer un pas α "convenable" ?

Créate : pour f par quad, une direct° d et un point n (on se situe en n), la situation est la suivante si d est un direct° de descente :



Condition W1 : le pas α à identifier doit nous faire descendre!

— Dérivée : le pas α à droite légèrement inclinée

$$f(n + \alpha d) \leq f(n) + \beta_1 \alpha d^T \nabla f(n) \quad \text{avec } \beta_1 \leq \alpha \leq \beta_2$$

$$\text{Tangente : } f(n) + \alpha d^T \nabla f(n) \quad \begin{cases} n^+ = n + \alpha d \\ n^- = n - \alpha d \end{cases} \quad \begin{cases} \alpha \leq \beta_1 \\ \alpha \geq \beta_2 \end{cases}$$

Condition W2 : Essayons de pas choisir des pas trop petits

$$d^T \nabla f(n + \alpha d) \geq \beta_2 d^T \nabla f(n) \quad \begin{cases} \beta_1 \leq \alpha \leq \beta_2 \\ \beta_1 \leq \beta_2 \end{cases}$$

→ la pente doit être à chaque fois un petit peu plus négative.

$$\text{Avec } 0 < \beta_1 \leq \beta_2 < 1$$

Algorithme de calcul de α à savoir implémenter !!!

Méthode permettant de déterminer un pas α vérifiant les conditions W1 et W2.

Certains à EXAM qu'on va avoir ça.

On se donne : $\alpha_0, 0 < \beta_1 < \beta_2 < 1$ et $\lambda > 1$

- 1 Initialisation : $i = 0, \alpha_l = 0$ et $\alpha_r = +\infty$.
- 2 Si α_i vérifie W1 et W2, alors $\alpha^* = \alpha_i$, STOP.
- 3 Si α_i viole W1, alors le pas est trop long.

$$\alpha_r = \alpha_i$$

$$\alpha_{i+1} = \frac{\alpha_l + \alpha_r}{2}$$

- 4 Si α_i ne viole pas W1 mais viole W2, alors le pas est trop court.

$$\alpha_l = \alpha_i$$

$$\alpha_{i+1} = \begin{cases} \frac{\alpha_l + \alpha_r}{2} & \text{si } \alpha_r < +\infty \\ \lambda \alpha_i & \text{sinon.} \end{cases}$$

- 5 $i = i + 1$

PREUVE (1)

Preuve (1) Zerkendijk:

$$\text{On part de w2: } \beta_2 d^T \nabla f(n) \leq d^T \nabla f(n+ad) - d^T \nabla f(n) \quad (\text{on fait - de chaque côté})$$

$$\Rightarrow (\beta_2 - 1) d^T \nabla f(n) \leq d^T (\nabla f(n+ad) - \nabla f(n)) \leq \|d\| \cdot \|\nabla f(n+ad) - \nabla f(n)\| \leq \|d\| \cdot L \cdot \|n+ad - n\| = \alpha \cdot L \|d\|^2$$

$$\frac{d^T \nabla f(n)}{L} \leq \alpha \cdot L \|d\|^2 \Rightarrow (\beta_2 - 1) d^T \nabla f(n) \leq \alpha \cdot L \|d\|^2 \Rightarrow d^T \nabla f(n) \leq \frac{\alpha \cdot L}{\beta_2 - 1} \|d\|^2$$

↑ utilise hypo L-smooth

$$\text{Utilise w1: } f(n+ad) \leq f(n) + \beta_2 \cdot \alpha \cdot d^T \nabla f(n) \leq f(n) + \frac{\beta_2 (\beta_2 - 1)}{L \|d\|^2} d^T \nabla f(n) = \cos^2(\theta) \|\nabla f(n)\|^2$$

$$\Rightarrow f(n+ad) \leq f(n) - \frac{(\beta_2 - 1) \cos^2(\theta)}{L} \|\nabla f(n)\|^2$$

→ la CS s'applique. > 0 ($\theta < \pi/2$)

⇒ On converge vers un pt stationnaire

Cqfd

PREUVE (2)

Preuve (2) (avec $d = -\nabla f(n)$ et $\alpha = \frac{1}{L}$ pour f L-smooth)

$$\text{Itérés: } n^+ = n - \alpha \nabla f(n)$$


$$\text{Par Taylor: } f(n^+) = f(n) + \nabla f(n)^T (n^+ - n) + \frac{1}{2} (n^+ - n)^T \nabla^2 f(\xi) (n^+ - n)$$

$$= f(n) - \alpha \|\nabla f(n)\|^2 + \frac{\alpha^2}{2} \nabla f(n)^T \nabla^2 f(\xi) \nabla f(n) \leq L \cdot \alpha^2 \|\nabla f(n)\|^2$$

$$\leq f(n) - \alpha \left(1 - \frac{\alpha L}{2}\right) \|\nabla f(n)\|^2$$

$$f(n^+) \leq f(n) - \frac{1}{2L} \|\nabla f(n)\|^2 \Rightarrow \text{CS s'applique} \Rightarrow \text{On converge vers un pt stationnaire.}$$

Cqfd



$$\text{Avec } \alpha = \frac{1}{L} \quad \alpha \in]0; \frac{1}{L}[$$

Et quelle vitesse on converge lorsque f est convexe?

PREUVE (3)

 f convexe: $f(y) \geq f(n) + \nabla f(n)^T (y - n) \quad \forall n, y$

$$\text{En } y = n^*, \quad f(n^*) \geq f(n) + \nabla f(n)^T (n^* - n) \Rightarrow f(n) \leq f(n^*) + \nabla f(n)^T (n^* - n) \quad (2)$$

$$\text{Combinons (1) et (2): } f(n^+) \leq f(n^*) + \nabla f(n)^T (n - n^*) - \frac{1}{2L} \|\nabla f(n)\|^2$$

$$f(n^+) - f(n^*) \leq \frac{1}{2} \left(\frac{1}{L} \nabla f(n)^T (n - n^*) - \frac{1}{L^2} \|\nabla f(n)\|^2 \right) + \|n - n^*\|^2 - \|n - n^*\|^2$$

$$\leq \frac{L}{2} \left(\|n - n^*\|^2 - \left\| n - \frac{1}{L} \nabla f(n) - n^* \right\|^2 \right)$$

$$= \frac{L}{2} \left(\|n - n^*\|^2 - \|n^+ - n^*\|^2 \right)$$

$$\Rightarrow f(n^{(k+1)}) - f(n^*) \leq \frac{L}{2} (\|n^{(k)} - n^*\|^2 - \|n^{(k+1)} - n^*\|^2)$$

→ forme un terme comme $-(a-b)^2 = -a^2 + 2ab - b^2$

→ On fait $k = 3$ itérés

$$f(n^{(k)}) - f(n^*) \leq f(n^{(k)}) - f(n^*) \leq \frac{L}{2} (\|n^{(k)} - n^*\|^2 - \|n^{(k+1)} - n^*\|^2)$$

$$f(n^{(k)}) - f(n^*) \leq f(n^{(k)}) - f(n^*) \leq \frac{L}{2} (\|n^{(k)} - n^*\|^2 - \|n^{(k+1)} - n^*\|^2)$$

$$+ f(n^{(k)}) - f(n^*) \leq f(n^{(k)}) - f(n^*) \leq \frac{L}{2} (\|n^{(k)} - n^*\|^2 - \|n^{(k+1)} - n^*\|^2)$$

$$k \cdot (f(n^{(k)}) - f(n^*)) \leq \frac{L}{2} (\|n^{(0)} - n^*\|^2 - \|n^{(k)} - n^*\|^2)$$

$$\Rightarrow f(n^{(k)}) - f(n^*) \leq \frac{L}{2} \|n^{(0)} - n^*\|^2 \cdot \frac{1}{k} \quad \text{vitesse sous linéaire (pas terrible !!)} \quad O\left(\frac{1}{k}\right)$$

Notation

Pour une tolérance choisie ε (par ex., $\varepsilon = 10^{-6}$), on souhaite trouver $x^{(k)}$ tel que $f(x^{(k)}) \leq f(x^*) + \varepsilon$.

Combien d'itérations k sont nécessaires pour atteindre cette tolérance ?

- Si le nombre d'itérations $k = \mathcal{O}\left(\frac{1}{\varepsilon^2}\right)$, cela signifie que

$$k = \text{constante} \cdot \frac{1}{\varepsilon^2}.$$

On notera alors $\varepsilon = \mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$.

- Si le nombre d'itérations $k = \mathcal{O}\left(\frac{1}{\varepsilon}\right)$, cela signifie que

$$k = \text{constante} \cdot \frac{1}{\varepsilon}.$$

On notera alors $\varepsilon = \mathcal{O}\left(\frac{1}{k}\right)$.

- Si le nombre d'itérations $k = \mathcal{O}\left(\frac{1}{\sqrt{\varepsilon}}\right)$, cela signifie que

$$k = \text{constante} \cdot \frac{1}{\sqrt{\varepsilon}}.$$

On notera alors $\varepsilon = \mathcal{O}\left(\frac{1}{k^2}\right)$.

- Si le nombre d'itérations $k = \mathcal{O}\left(\log\left(\frac{1}{\varepsilon}\right)\right)$, cela signifie que

$$k = \text{constante} \cdot \log\left(\frac{1}{\varepsilon}\right).$$

On notera alors $\varepsilon = \mathcal{O}(c^k)$.

De + en + vite

À quelle vitesse on converge lorsque f est strictement convexe ?

PREUVE (4)

f strictement convexe

Par Taylor : $f(y) = f(n) + \nabla f(n)^T (y-n) + \frac{1}{2} (y-n)^T \nabla^2 f(c) (y-n)$

$f(y) \geq f(n) + \nabla f(n)^T (y-n) + \frac{\mu}{2} \|y-n\|^2 \geq f(n) + \nabla f(n)^T \left(-\frac{1}{\mu} \nabla f(n)\right) + \frac{\mu}{2} \frac{1}{\mu^2} \|\nabla f(n)\|^2$

$f(y) \geq f(n) - \frac{1}{2\mu} \|\nabla f(n)\|^2$

→ de $\|y-n\|^2$ car f strict. convexe, la + petite valeur de $\nabla^2 f \geq \mu > 0$

Cette qte est la + petite en $y = n - \frac{1}{\mu} \nabla f(n)$

Donc en $y = n^*$: $f(n^*) \geq f(n) - \frac{1}{2\mu} \|\nabla f(n)\|^2 \Rightarrow -\|\nabla f(n)\|^2 \leq 2\mu (f(n^*) - f(n))$

J'utilise (1) : $f(n^*) \leq f(n) - \frac{1}{2L} \|\nabla f(n)\|^2 \leq f(n) - \frac{2\mu}{2L} (f(n^*) - f(n))$

$f(n^*) - f(n^*) \leq f(n) - f(n^*) - \frac{\mu}{L} (f(n) - f(n^*))$

$f(n^*) - f(n^*) \leq \left(1 - \frac{\mu}{L}\right) (f(n^*) - f(n^*)) \Rightarrow \text{CONVERGENCE LINÉAIRE}$

$\mu_{aux} = 1 - \frac{\mu}{L} < 1$ *→ $f(n^*) = f(n^*) \cdot \mu^k$*

Gradient accéléré

Contrairement à la méthode du gradient de base (figure de gauche), on va également utiliser l'information de l'itération précédente (figure de droite) :



- 1 Choisir le paramètre $\alpha_1 \in (0, 1)$;
- 2 Choix du point initial $x^{(0)}$. On définit $y = x^{(0)}$.
- 3 $k = 1, 2, \dots$

- 1 $x^{(k)} = y - \frac{1}{L} \nabla f(y).$

- 2 $y = x^{(k)} + \beta_k (x^{(k)} - x^{(k-1)}),$

où $\beta_k = \frac{\alpha_k(1-\alpha_k)}{\alpha_k^2 + \alpha_{k+1}}$ avec $\alpha_{k+1} \geq 0$ t.q. $\alpha_{k+1}^2 = (1 - \alpha_{k+1})\alpha_k^2.$

En utilisant $\beta_k = 0$ pour tout k , on retrouve l'algorithme du gradient.